

数据增强型 AutoML 市场的机制改进

概念解读、数学模型、伪代码与实验验证

基于《Optimal Pricing for Data-Augmented AutoML Marketplaces》的课程项目扩展

2026 年 7 月 24 日 版本 0.7.1

摘要

原论文把数据增强、AutoML 模型发现、买家最优停止与性能提升定价连接成一个统一市场。其核心思想是：平台不按数据表数量或训练计算量收费，而是对最终可测的模型性能提升发布价格曲线。该框架具有清晰的经济含义，但从复现走向部署时仍有四个关键边界：论文式定价实验采用强制购买口径；平台在冷启动阶段并不知道真实买家先验；非零搜索成本会改变买家的停止行为；数据发现过程与后续收入目标相互割裂。

本文详细说明项目在不改变“按性能提升定价”主线的前提下所做的四项改进：加入不购买外部选项；用精确状态传播实现成本感知 Markov 定价；在多个先验与搜索成本场景上做有限场景 max-min 鲁棒优化；用 warm-start 价格信号引导 Data-Bandit。报告给出概念解释、目标函数、动态规划、状态传播、四段伪代码、复杂度、实验设置、主实例与多实例结果、价格信号消融以及适用边界。实验表明，Cost-aware Markov 在名义市场中收入最高，Robust cost-aware Markov 提高最坏情况收入，而 Pricing-guided Data-Bandit 能更早发现高价值增强；这些收益均伴随明确的假设和权衡。

目录

1 阅读目标与改进总览	3
2 原论文模型：改进从哪里开始	3
2.1 质量、买家类型与价格曲线	3
2.2 论文式样本平均定价	3
2.3 四个部署边界	4
3 改进一：外部选项与自愿购买语义	4
3.1 概念解读	4
4 改进二：成本感知的精确 Markov 定价	5
4.1 为什么集合压缩在 $c > 0$ 时失效	5
4.2 最优停止动态规划	5
4.3 精确状态前向传播	6
4.4 成本感知价格优化	7

目录	2
5 改进三：有限场景鲁棒定价	7
5.1 冷启动与分布偏移	7
5.2 静态 Robust IR 与动态联合鲁棒目标	7
6 改进四：warm-start 价格引导 Data-Bandit	8
6.1 发现与定价为何需要反馈	8
7 复杂度与实现对应	9
7.1 复杂度	9
7.2 代码映射	10
8 实验设计与评价指标	10
8.1 定价实验	10
8.2 发现实验	11
9 实验结果：定价改进	12
10 实验结果：定价引导发现	14
11 测试、复现命令与产物	15
12 结论与适用边界	16

1 阅读目标与改进总览

这份报告回答三个问题：

1. 原论文模型的部署边界究竟是什么，为什么不能只改实验口径而不改买家响应？
2. 每项改进修改了哪个数学对象：可选集合、动态收入、优化目标，还是发现算法？
3. 实验数字能支持多强的结论，哪些结果不能外推为一般理论？

表 1: 四项改进与原模型边界的对应关系。

改进	原模型边界	修改的核心对象	主要验证指标
外部选项 / IR-aware	强制每个买家购买	买家可选集合加入零效用、零支付选项	自愿购买实现收入
成本感知 Markov	$c \approx 0$ 时把轨迹压缩为集合	价格、停止策略、Markov 顺序联合进入收入	精确动态收入
有限场景鲁棒定价	买家先验和搜索成本被视为已知	最大化多个先验/成本场景中的最坏收入	最坏场景收入
价格引导 Data-Bandit	发现与定价分成独立模块	访问顺序与 bandit 奖励加入 warm-start 收入信号	AUC、早期效用

一句话理解

四项改进不是把市场改回“按数据量收费”，而是在同一条性能提升价格曲线 $x(q)$ 上依次修正“可以买不买”“何时停止”“先验不确定”和“先发现什么”四个问题。

2 原论文模型：改进从哪里开始

2.1 质量、买家类型与价格曲线

设离散质量空间为 $\mathcal{Q} = \{1, \dots, Q\}$ ，买家类型集合为 $\Theta = \{1, \dots, K\}$ 。类型 θ 对质量 q 的估值为 $v^\theta(q)$ ，平台公布价格曲线 $x(q) \geq 0$ 。买家从质量 q 得到的净价值为

$$u^\theta(q; x) = v^\theta(q) - x(q).$$

AutoML 发现过程产生随机质量序列 $Q_1, Q_2, \dots, Q_T$ 。初始状态服从 ρ ，转移概率为

$$P_t(q' | q) = \Pr(Q_{t+1} = q' | Q_t = q).$$

平台不直接出售某张外部数据表，而是出售发现过程最终带来的可测质量或性能提升。

2.2 论文式样本平均定价

当每轮搜索成本近似为零时，一条轨迹的到达顺序不再重要，可以压缩为出现过的质量集合 $s \subseteq \mathcal{Q}$ 。论文式 forced-choice 响应为

$$q_{\theta, s}^{\text{FC}}(x) \in \arg \max_{q \in s} \{v^\theta(q) - x(q)\}.$$

给定 m 个样本集合 $s_1, \dots, s_m$ 和类型先验 μ ，经验收入为

$$\widehat{\text{Rev}}_{\text{FC}}(x; \mu) = \sum_{\theta \in \Theta} \mu_{\theta} \frac{1}{m} \sum_{j=1}^m x(q_{\theta, s_j}^{\text{FC}}(x)).$$

该目标适合复现论文的定价 MILP，但它隐含一个强假设：即使所有质量的净效用都为负，买家仍必须选一个质量并付款。这是第一项改进的起点。

2.3 四个部署边界

1. **购买语义**：真实买家可以退出；forced-choice 收入可能记录经济上无法实现的支付。
2. **顺序与成本**：当 $c > 0$ 时，晚出现的高质量未必能被买家等到；相同到达集合可能产生不同收入。
3. **参数不确定**：最优价格依赖类型先验 μ 和搜索成本 c ，而冷启动时两者都可能估计不准。
4. **发现目标**：普通 Data-Bandit 追求尽快发现高验证效用组合，但平台最终关心的还包括可实现收入。

3 改进一：外部选项与自愿购买语义

3.1 概念解读

外部选项表示“什么也不买”。记该选项为 $\emptyset$ ，规定

$$v^{\theta}(\emptyset) = 0, \quad x(\emptyset) = 0, \quad u^{\theta}(\emptyset; x) = 0.$$

于是买家的真实选择变为

$$q_{\theta, s}^{\text{IR}}(x) \in \arg \max_{q \in s \cup \{\emptyset\}} \{v^{\theta}(q) - x(q)\}.$$

相应的经验实现收入为

$$\widehat{\text{Rev}}_{\text{IR}}(x; \mu) = \sum_{\theta \in \Theta} \mu_{\theta} \frac{1}{m} \sum_{j=1}^m x(q_{\theta, s_j}^{\text{IR}}(x)),$$

其中 $x(\emptyset) = 0$ 。

为什么称为“语义修正”

外部选项并不是一个新的收费规则。平台仍对性能提升质量 q 定价；变化只在于买家不会在所有净效用为负时被迫购买。因此 IR-aware 的首要作用是让评价指标与可退出市场一致，而不是保证收入必然超过所有基线。

命题 3.1 (个体理性)。在外部选项下，买家的购买前净效用满足

$$\max_{q \in s \cup \{\emptyset\}} u^{\theta}(q; x) \geq 0.$$

因此买家不会被分配到严格负净效用的质量。

算法 1 带外部选项的买家响应与支付**输入：** 可达质量集合 s , 估值 v^θ , 价格曲线 x **输出：** 所选质量 q^* 与平台支付 p

```

1:  $q^* \leftarrow \emptyset, U^* \leftarrow 0, p \leftarrow 0$ 
2: for  $q \in s$  do
3:    $U \leftarrow v^\theta(q) - x(q)$ 
4:   if  $U > U^*$ , 或  $U = U^*$  且  $x(q) > p$  then
5:      $q^* \leftarrow q, U^* \leftarrow U, p \leftarrow x(q)$ 
6:   end if
7: end for
8: return  $(q^*, p)$ 

```

实现使用卖方有利的效用平局处理：若买家在零效用购买与退出之间无差异，可以选择价格更高的同效用质量。报告结果因此应理解为声明过的平局规则下的收入，而不是所有平局规则下的下界。

4 改进二：成本感知的精确 Markov 定价

4.1 为什么集合压缩在 $c > 0$ 时失效

考虑两条轨迹 (q_L, q_H) 与 (q_H, q_L) 。二者可达集合相同，但如果继续搜索需要支付成本，第一条轨迹中的买家可能在 q_L 就停止，而第二条轨迹一开始便能购买 q_H 。因此收入不仅取决于“见过哪些质量”，还取决于出现顺序、剩余时域和转移概率。

命题 4.1 (价格-停止耦合)。当搜索成本 $c > 0$ 时，一般不存在只依赖最终可达集合 s 的收入函数，能够对所有到达顺序准确表示平台收入。

4.2 最优停止动态规划

对类型 θ ，令 b 表示历史上净价值最高的质量， q 表示当前质量。若下一轮出现 q' ，历史最佳状态更新为

$$B_x^\theta(b, q') = \begin{cases} b, & u^\theta(b; x) \geq u^\theta(q'; x), \\ q', & u^\theta(q'; x) > u^\theta(b; x). \end{cases}$$

第 t 轮停止时，前 t 轮搜索成本已经发生。允许退出时的停止价值为

$$S_t^\theta(b; x, c) = \max\{u^\theta(b; x), 0\} - ct.$$

终点必须停止：

$$V_T^\theta(b, q) = S_T^\theta(b; x, c).$$

对 $t < T$ ，Bellman 递推为

$$V_t^\theta(b, q) = \max \left\{ S_t^\theta(b; x, c), \sum_{q' \in \mathcal{Q}} P_t(q' | q) V_{t+1}^\theta(B_x^\theta(b, q'), q') \right\}.$$

若右侧继续价值严格大于停止价值，则策略 $\pi_t^\theta(b, q; x, c) = 1$ ，否则停止。

4.3 精确状态前向传播

只求出停止策略还不等于求出收入。项目进一步传播状态概率，而不是采样有限条轨迹。令

$$\alpha_t^\theta(b, q) = \Pr(\text{第 } t \text{ 轮仍活跃且状态为 } (b, q) \mid \theta).$$

初始概率为

$$\alpha_1^\theta(b, q) = \rho(q) \mathbb{I}\{b = q\}.$$

若状态继续，则

$$\alpha_{t+1}^\theta(b', q') += \alpha_t^\theta(b, q) P_t(q' \mid q), \quad b' = B_x^\theta(b, q').$$

精确类型收入为

$$\text{Rev}_\theta(x; c) = \sum_{t=1}^T \sum_{b, q} \alpha_t^\theta(b, q) \mathbb{I}\{\text{在 } (t, b, q) \text{ 停止}\} x(b) \mathbb{I}\{u^\theta(b; x) \geq 0\}.$$

市场总收入为

$$\text{Rev}(x; \mu, c) = \sum_{\theta \in \Theta} \mu_\theta \text{Rev}_\theta(x; c).$$

算法 2 给定价格下的精确 Markov 期望支付

输入： $x, v^\theta, \rho, P_{1:T-1}, T, c$ ，是否允许退出

输出： 类型 θ 的精确期望支付 R_θ

```

1: 用 Bellman 递推求继续策略  $\pi^\theta$ 
2: 初始化  $\alpha(b, q) \leftarrow \rho(q) \mathbb{I}\{b = q\}$ ,  $R_\theta \leftarrow 0$ 
3: for  $t = 1, \dots, T$  do
4:   初始化下一轮概率  $\alpha^+(b, q) \leftarrow 0$ 
5:   for all  $(b, q)$  且  $\alpha(b, q) > 0$  do
6:     if  $t = T$  或策略要求停止 then
7:       if 强制购买, 或  $v^\theta(b) - x(b) \geq 0$  then
8:          $R_\theta \leftarrow R_\theta + \alpha(b, q)x(b)$ 
9:       end if
10:    else
11:      for all  $q'$  且  $P_t(q' \mid q) > 0$  do
12:         $b' \leftarrow B_x^\theta(b, q')$ 
13:         $\alpha^+(b', q') \leftarrow \alpha^+(b', q') + \alpha(b, q)P_t(q' \mid q)$ 
14:      end for
15:    end if
16:  end for
17:   $\alpha \leftarrow \alpha^+$ 
18: end for
19: return  $R_\theta$ 

```

4.4 成本感知价格优化

对每个质量给定有限候选价格集合 $\mathcal{G}_q$ ，价格网格为 $\mathcal{G} = \prod_{q \in \mathcal{Q}} \mathcal{G}_q$ 。名义成本感知价格为

$$x_{\text{CA}}^* \in \arg \max_{x \in \mathcal{G}} \text{Rev}(x; \mu, c_0).$$

这里的“精确”指：对给定价格、有限状态 *Markov* 环境和声明的时域，收入通过状态传播精确计算。价格优化仍限制在有限网格 $\mathcal{G}$ 上，因此不宣称是一般连续价格空间中的全局最优解。

5 改进三：有限场景鲁棒定价

5.1 冷启动与分布偏移

平台的价格依赖买家类型先验 μ ，但真实先验通常要通过多轮交易学习。若直接把早期估计当成真值，价格会对冷启动误差和用户结构变化十分敏感。项目用一组可解释场景代替单一估计：

$$\mathcal{M} = \{\mu^{(1)}, \dots, \mu^{(L)}\}, \quad \mathcal{C} = \{c^{(1)}, \dots, c^{(J)}\}.$$

本实验包括训练先验、OOS 低估值偏移先验、均匀冷启动先验和高估值偏移先验。搜索成本场景为

$$c \in \{0, 0.03, 0.08\}.$$

5.2 静态 Robust IR 与动态联合鲁棒目标

静态 Robust IR 在样本集合收入上求

$$x_{\text{RIR}}^* \in \arg \max_{x \in \mathcal{G}} \min_{\mu \in \mathcal{M}} \widehat{\text{Rev}}_{\text{IR}}(x; \mu).$$

动态 Robust cost-aware Markov 则求

$$x_{\text{RCA}}^* \in \arg \max_{x \in \mathcal{G}} \min_{\mu \in \mathcal{M}, c \in \mathcal{C}} \text{Rev}(x; \mu, c).$$

鲁棒性意味着什么

鲁棒目标不是追求每个场景都最好，而是提高最差场景的收入下界。它通常会牺牲名义场景收入，因此适合先验不可靠、搜索成本波动大或平台更重视保守保障的情形。

算法 3 有限场景鲁棒成本感知定价**输入：** 价格网格 $\mathcal{G}$, 估值矩阵 V , 先验场景 $\mathcal{M}$, 成本场景 $\mathcal{C}$, Markov 环境**输出：** 鲁棒价格 x^* 与最坏场景收入 z^*

```

1:  $z^* \leftarrow -\infty$ 
2: for all  $x \in \mathcal{G}$  do
3:    $z(x) \leftarrow +\infty$ 
4:   for all  $c \in \mathcal{C}$  do
5:     for all  $\theta \in \Theta$  do
6:       用算法 2 计算  $R_\theta(x; c)$ 
7:     end for
8:     for all  $\mu \in \mathcal{M}$  do
9:        $z(x) \leftarrow \min\{z(x), \sum_\theta \mu_\theta R_\theta(x; c)\}$ 
10:    end for
11:  end for
12:  if  $z(x) > z^*$  then
13:     $(x^*, z^*) \leftarrow (x, z(x))$ 
14:  end if
15: end for
16: return  $(x^*, z^*)$ 

```

理论边界

该方法是**有限场景 max-min**，不是 Wasserstein、KL 球或 ϕ -divergence 意义下的完整分布鲁棒优化。最坏情况保证只覆盖显式列入 $\mathcal{M} \times \mathcal{C}$ 的场景，不覆盖所有可能市场。

6 改进四：warm-start 价格引导 Data-Bandit

6.1 发现与定价为何需要反馈

普通 Data-Bandit 的目标是用较少模型训练尽快找到高验证效用的“增强 + 模型”组合。它默认按候选增强的原顺序访问，并只用验证效用更新模型 bandit。可是两个验证效用相近的增强可能对应不同可售质量、买家需求或支付水平。若平台已经从历史交易、元数据或相似任务获得方向性收入信号，就可以把该信号作为 warm-start 信息反馈给发现过程。

设增强集合为 $\mathcal{A} = \{1, \dots, A\}$ ，模型集合为 $\mathcal{M} = \{1, \dots, M\}$ ，验证效用为 $y_{a,m}$ ，外生价格信号为 s_a 。先归一化：

$$\tilde{s}_a = \begin{cases} \frac{s_a - \min_j s_j}{\max_j s_j - \min_j s_j}, & \max_j s_j > \min_j s_j, \\ 0, & \text{否则.} \end{cases}$$

将验证奖励裁剪到 $[0, 1]$ ，并构造引导奖励

$$r_{a,m}^{\text{guided}} = (1 - \lambda) \text{clip}(y_{a,m}, 0, 1) + \lambda \tilde{s}_a, \quad \lambda \in [0, 1].$$

模型选择概率沿用 Exp3 风格：

$$p_m = (1 - \gamma) \frac{w_m}{\sum_j w_j} + \frac{\gamma}{M},$$

抽取模型 m 后更新

$$w_m \leftarrow w_m \exp \left(\min \left\{ \frac{\gamma r_{a,m}^{\text{guided}}}{M p_m}, 20 \right\} \right).$$

指数截断为 20 是数值稳定措施，不改变算法的概念方向。

算法 4 Pricing-guided Data-Bandit

输入： score table, 预算 B , 信号 $s_{1:A}$, γ , 价格权重 λ

输出： 长度为 B 的 incumbent 测试效用曲线

- 1: 计算归一化信号 $\tilde{s}$; 按 $\tilde{s}_a$ 降序稳定排序增强
 - 2: 初始化模型权重 $w_m \leftarrow 1$
 - 3: **for all** 排序后的增强 a **do**
 - 4: **if** 预算已用完 **then**
 - 5: **return** 当前曲线
 - 6: **end if**
 - 7: $p_m \leftarrow (1 - \gamma) w_m / \sum_j w_j + \gamma / M$
 - 8: 按 p 抽取模型 m , 训练并读取验证效用 $y_{a,m}$
 - 9: $r \leftarrow (1 - \lambda) \text{clip}(y_{a,m}, 0, 1) + \lambda \tilde{s}_a$
 - 10: $w_m \leftarrow w_m \exp(\min\{\gamma r / (M p_m), 20\})$
 - 11: 依据验证 incumbent 记录对应测试效用
 - 12: **end for**
 - 13: 用最高权重模型复查引导奖励最高的 $\lceil \log_2 A \rceil$ 个增强
 - 14: 在引导奖励最高增强上尝试全部模型
 - 15: 在当前验证 incumbent 增强上尝试全部模型, 直到预算耗尽
 - 16: **return** incumbent 曲线
-

信号来源与数据泄漏

价格信号必须来自历史交易、任务元数据、上一批市场反馈或其他部署时可获得信息，不能由当前测试集反推。冷启动第一单若没有可靠信号，应退回普通 Data-Bandit 或使用明确声明的弱元数据先验。

7 复杂度与实现对应

7.1 复杂度

对单个类型和单条价格曲线，最优停止表含 TQ^2 个状态，每个状态枚举 Q 个下一质量，时间复杂度为

$$O(TQ^3), \quad \text{空间复杂度为 } O(TQ^2).$$

精确支付前向传播具有同阶最坏时间复杂度。若价格网格大小为 $|\mathcal{G}|$ ，类型数为 K ，则名义成本感知枚举的最坏复杂度为

$$O(|\mathcal{G}|KTQ^3).$$

联合鲁棒版本再乘以成本场景数 J 。先验场景只对已经得到的类型收入做线性加权，增加的工作量约为

$$O(|\mathcal{G}|JLK).$$

Pricing-guided Data-Bandit 的额外计算主要是 $O(A \log A)$ 的信号排序；真正昂贵的部分仍是预算内最多 B 次模型训练。

7.2 代码映射

文件	作用
src/automl_market/market.py	最优停止 DP、精确停止分布、精确期望支付、时间变化转移矩阵支持。
src/automl_market/pricing.py	forced-choice / 外部选项响应、静态有限网格定价、Robust IR、Independent/Shift/Jiggle。
src/automl_market/dynamic_pricing.py	成本感知 Markov 收入、先验/成本场景联合 max-min 优化。
src/automl_market/discovery.py	普通 Data-Bandit 与 Pricing-guided Data-Bandit。
src/automl_market/improvement_experiments.py	主实例、5 个扰动市场、12 个信号消融实例、表格与图。
scripts/run_improvement_experiments.py	命令行实验入口。
tests/test_core.py、tests/test_discovery.py	外部选项、精确支付、时间转移、鲁棒目标、价格信号和预算语义测试。

8 实验设计与评价指标

8.1 定价实验

主实例包含 4 个质量状态、6 个买家类型、有限时域 Markov 发现过程。比较六种方法：

1. Paper forced-choice;
2. Independent;
3. IR-aware;

4. Robust IR;
5. Cost-aware Markov;
6. Robust cost-aware Markov。

评价包括名义先验、OOS 偏移先验，以及四个先验与三个搜索成本的最坏组合。另生成 5 个扰动市场，报告均值和标准误：

$$\text{SE}(\bar{y}) = \frac{s(y_1, \dots, y_n)}{\sqrt{n}}.$$

8.2 发现实验

主 score table 的预算为 $B = 16$ 。发现曲线为 $g_1, \dots, g_B$ ，其中 g_b 是完成 b 次模型训练后验证 incumbent 对应的测试效用。归一化 AUC 定义为

$$\text{AUC} = \frac{1}{B} \sum_{b=1}^B g_b.$$

若基础效用为 g_0 、oracle 效用为 g^* ，95% oracle 增益阈值为

$$g_{95} = g_0 + 0.95(g^* - g_0).$$

报告第一次达到该阈值所需训练数；若预算内未达到，记为 $B + 1 = 17$ 。此外报告前 4 次训练平均效用，专门衡量极低预算阶段的收益。

信号消融在 12 个扰动 score table 上比较：

- 普通 Data-Bandit;
- Random-signal guided;
- Noisy-pricing guided;
- Pricing-guided Data-Bandit。

该消融用于区分“改变访问顺序本身”与“价格信号包含的信息”。

9 实验结果：定价改进




图 1: 主实例：名义先验、OOS 先验和最坏先验/成本下的精确 Markov 收入。

表 3: 主实例的精确 Markov 收入。

方法	名义 $c = 0.03$	OOS 先验 $c = 0.03$	最坏先验/成本
Paper forced-choice	0.1658	0.0622	0.0296
Independent	0.2838	0.1927	0.1490
IR-aware	0.2634	0.1702	0.1366
Robust IR	0.2478	0.1729	0.1317
Cost-aware Markov	0.3082	0.2231	0.1592
Robust cost-aware Markov	0.2347	0.2049	0.1857

主实例怎样解读

- Cost-aware Markov 相比 Independent 的名义收入提高约 8.6%，OOS 先验收入提高约 15.8%，说明搜索成本与停止顺序确实会改变最优价格。
- Robust cost-aware Markov 相比 Independent 的最坏情况收入提高约 24.6%。
- 鲁棒方案的代价很明确：相对 Cost-aware Markov，其名义收入下降约 23.9%。因此“鲁棒”不等于“所有指标都高”。
- IR-aware 的意义首先是口径正确；它在本主实例上没有支配 Independent。




图 2: 5 个扰动市场上的定价收入均值与标准误。

表 4: 5 个扰动市场的均值 $\pm$ 标准误。

方法	名义 $c = 0.03$	OOS 先验 $c = 0.03$	最坏先验/成本
Paper forced-choice	0.1451 ± 0.0273	0.0673 ± 0.0137	0.0417 ± 0.0094
Independent	0.2600 ± 0.0107	0.1698 ± 0.0053	0.1527 ± 0.0026
IR-aware	0.2217 ± 0.0250	0.1503 ± 0.0131	0.1257 ± 0.0072
Robust IR	0.2644 ± 0.0158	0.1814 ± 0.0130	0.1411 ± 0.0112
Cost-aware Markov	0.3072 ± 0.0116	0.2079 ± 0.0056	0.1614 ± 0.0034
Robust cost-aware Markov	0.2420 ± 0.0131	0.2041 ± 0.0045	0.1843 ± 0.0033

多实例结果保持相同排序：名义市场偏向 Cost-aware Markov，最坏情况偏向 Robust cost-aware Markov。5 个实例仍然是小样本，因此标准误只能表示这组透明扰动下的稳定性，不能替代更大规模统计检验。

10 实验结果：定价引导发现




图 3: 主 score table: Pricing-guided Data-Bandit 更早进入高效用区域。

表 5: 主 score table 的发现结果，预算为 16。

方法	最终效用	AUC	95% 训练数	前 4 次效用
Data-Bandit	0.7460	0.6949	17	0.5415
Data-All	0.5960	0.5470	17	0.5015
Data-Alt	0.8060	0.6678	12	0.5345
AutoML	0.5060	0.5049	17	0.5015
Pricing-guided Data-Bandit	0.8060	0.7583	13	0.7350

主发现实验怎样解读

Pricing-guided Data-Bandit 相比普通 Data-Bandit 的 AUC 增加 0.0634，前 4 次训练平均效用提高约 35.7%。它最终达到 0.8060，与 Data-Alt 并列最高。收益集中在“更早发现”，这正是 warm-start 信号应发挥作用的阶段。




图 4: 12 个扰动 score table 上的价格信号消融。

表 6: 价格信号消融，均值 $\pm$ 标准误。

方法	AUC	前 4 次效用
Data-Bandit	0.7191 ± 0.0042	0.5418 ± 0.0009
Random-signal guided	0.7588 ± 0.0081	0.7096 ± 0.0147
Noisy-pricing guided	0.7756 ± 0.0052	0.7566 ± 0.0071
Pricing-guided Data-Bandit	0.7764 ± 0.0070	0.7630 ± 0.0094

随机信号本身已经比普通 Data-Bandit 高，说明“改变访问顺序并更早集中探索”贡献了相当一部分收益。真实价格信号相对随机信号的 AUC 增量约为 0.0176，且 Noisy-pricing 与真实信号接近。因此正确结论是：warm-start 价格信号在排序收益之外提供了有限增量，而不是无条件显著优越。

11 测试、复现命令与产物

完整环境使用 `environment.yml`，其中固定 Python 主版本以及 NumPy、Matplotlib 和 HiGHS 版本。主要命令为：

```
conda run -n automl-market make test
conda run -n automl-market make improvements
conda run -n automl-market make improvement-report
```

当前 20 项单元测试全部通过。与本报告直接相关的测试覆盖：

- 外部选项能移除不可实现收入；
- 精确 Markov 支付遵循最优停止策略；
- 时间变化转移矩阵不会在终点越界；
- 鲁棒成本感知目标等于声明场景中的最坏收入；

- 价格信号会加入引导发现方法并优先高信号增强；
- 所有发现方法遵守模型训练预算。

数值依据位于：

- `results/improvement_experiments_summary.json`;
- `results/tables/improvement_pricing_results.csv`;
- `results/tables/improvement_pricing_multi_instance.csv`;
- `results/tables/improvement_discovery_results.csv`;
- `results/tables/improvement_discovery_signal_ablation.csv`。

12 结论与适用边界

1. **外部选项**让收入指标符合自愿购买语义，但不保证收入高于 Independent。
2. **成本感知 Markov 定价**把价格、停止策略、质量顺序与搜索成本放入同一动态目标；对给定价格的收入是精确的，价格搜索仍是有限网格。
3. **联合鲁棒定价**提高显式先验/成本场景中的收入下界，同时牺牲名义收入；它不是完整 DRO。
4. **价格引导发现**在存在可用 warm-start 信号时改善早期发现效率；冷启动第一单和真实信号构造仍是开放问题。

四项改进共同把原论文的理想化机制推进到更可部署的方向，但没有改变其核心价值主张：平台仍然对数据增强带来的可测模型性能提升收费，而不是按原始数据数量或训练计算量收费。现有实验构成了代码、测试、主实例、多实例、消融、表格和图像的闭环；下一步若继续研究，应优先扩展真实价格信号构造、更多市场实例、连续价格动态优化和严格分布鲁棒理论。

参考文献

- [1] Y. Han, S. Padmanabha, S. Wang, Z. Huang, and J. Zhao. Optimal Pricing for Data-Augmented AutoML Marketplaces. arXiv preprint arXiv:2310.17843, 2023.