

数据增强 AutoML 市场中的最优定价

论文理论解读 · 实验复现 · 机制讨论

张博渊、林润铎、彭博宇

数据要素市场课程 · 中期答辩

参考论文: *Optimal Pricing for Data-Augmented AutoML Marketplaces*

2026 年 7 月 18 日



机制重构

将分散在论文各节的模型整理为**轨迹**、**停止**、**定价**、**学习**四个环节。

结论提炼

从 DP、MILP 与学习理论中提炼四条可直接解释和检验的结论。

边界识别

明确结论成立所需的性能动态、买方偏好与信息条件。

数据本身值多少钱不是主要问题，而是模型增益值多少钱

直接售卖数据的错配

- 数据价值**依赖具体任务**，买方事前难判断是否有用；
- AutoML 按计算时间收费，买方可能为**无效搜索**承担成本；
- 不同买方对同一性能提升有不同支付意愿。

论文的定价对象

$$\Delta q = q(C \leftarrow D \bowtie A) - q(C_0 \leftarrow D)$$


数据增强与模型搜索共同产生的**工具性价值**

机制载体

平台预先公布统一价格曲线 $x(q)$ ，按买方最终购买的性能档位收费。

平台把数据发现、模型搜索与定价接成一个闭环

- 买方提交任务、初始训练数据和评估方式；平台从外部数据池中搜索增广特征与模型。
- 发现引擎持续输出性能轨迹，定价引擎将其转换为“性能-价格”菜单。



公开价格曲线同时处理性能、偏好与搜索成本

符号	在机制中的作用
$\mathcal{Q}, q_t$	离散化的模型性能集合与当前观测性能.
$P^t(q' q)$	性能从本期到下一期的搜索动态.
c, T	每期真实搜索成本与最长搜索期数.
$\theta \sim \mu$	买方类型及其先验; $v^\theta(q)$ 表示对性能的价值.
$x(q)$	平台面向所有买方公开的性能价格.

买方只比较一件事

$$\text{净效用} = \text{性能价值} - \text{价格} - \text{搜索成本}$$

买方通过停止时点表达自己的支付意愿

1. 进入前

平台公开价格、成本与性能演化信息.

2. 搜索中

每期看到最新性能, 保留已经出现的优质档位.

3. 自主决策

比较立即停止与继续搜索的期望收益.


4. 退出或购买

选择历史上净效用最高的档位, 也可以不购买.

机制性质

平台不要求买方主动报告类型; 不同支付意愿通过**停止时点与购买档位**自然表现出来.

结论 1: 买方遵循“立即停止还是继续搜索”的阈值规则



这是相关收益的 Pandora's Box

- 下一期性能依赖当前 q_t ;
- 决策需要记住历史最佳净效用;
- 搜索存在有限期限与逐期成本.

结论

若**立即停止效用**不低于**继续搜索的期望效用**, 买方停止; 否则继续.

结论 2: 三个状态量足以计算买方的最优停止

历史最好 q_1

到目前为止，净效用最高的性能档位.

当前性能 q_2

决定下一期性能的条件分布.

当前时间 t

决定剩余期限与累计搜索成本.

命题 4.1 的结论

动态规划只需遍历 $|Q|^2 T$ 个状态，最优停止策略可在 $O(|Q|^2 T)$ 时间内求得.
平台无需枚举所有搜索历史，只需维护这三个状态量，就能预测买方的最优响应.

结论 3：把买方选择写入 MILP，平台价格即可计算

原问题是双层优化

- 平台先选择价格曲线；
- 买方随后选择净效用最高的档位；
- 平台收入取决于买方的离散选择。

MILP 的转写思路

- x 表示公开价格；
- z 表示买方选择哪个档位；
- a 记录最大净效用；
- y 记录该选择带来的实际收入。

结论

通过 Big- M 约束把“买方最优选择”和“平台收入”同时编码后，可直接用标准 MILP 求解器输出整条价格曲线。

结论 4：有限轨迹足以学习近优价格

定理 4.2 及其结论

在买方价值有界、发现成本相对价值可忽略时，只要样本量满足

$$m \geq \frac{b^2}{2\varepsilon^2} \ln \frac{2}{\delta},$$

学到的价格曲线以至少 $1 - 2\delta$ 的概率达到距最优收入不超过 ε 的水平。

精度代价

ε 减半，所需样本量约增至四倍。

数据要求

只需采样真实性能轨迹，不必写出完整转移矩阵。

机制含义

价格曲线不仅可计算，而且能从有限历史任务中学习。

停止行为既能学习买方先验，也限制估计误差的损失

先验如何学习

- ① 观察买方在什么性能与时间停止；
- ② 比较不同类型产生该行为的可能性；
- ③ 反复交互后更新类型分布。

定理 5.2 的结论

若买方先验 μ 与性能动态 P 的估计误差均为 ε 量级，则平台收入损失仅为

$$O(\varepsilon).$$

前提

不同买方类型必须在某些价格下产生可区分的停止分布，否则仅凭行为无法识别类型。

发现引擎每轮只训练一个模型，持续输出可定价轨迹

为什么不能穷举

增广子集与模型的组合数量快速膨胀；
每轮测试全部模型会让搜索成本无法接受。

联合发现算法

- ① 用 Metam 聚类并选择候选增广；
- ② 将模型视作 Exp3 的不同臂；
- ③ 每轮只采样并训练**一个模型**；
- ④ 用当前性能更新模型权重。

与定价机制的接口

算法具备 anytime 性质：每轮输出一个 q_t ，买方可随时停止；性能序列正是停止策略与价格学习所需的轨迹。

四条建模边界决定理论结论能否成立

- ① **性能动态**: Q 有限离散, 未来性能只依赖当前性能与时间; 动态可公开或估计.
- ② **买方偏好**: 类型空间有限、价值有界; 不同类型的停止行为具有可识别性.
- ③ **价格形式**: 平台对所有买方公布同一条按性能收费的价格曲线, 不依赖主动报告.
- ④ **计算假设**: PAC 保证要求发现成本相对价值可忽略; 一般误差的收入影响由鲁棒性结论控制.

范围边界

论文主要解决” 买方停止决策 + 平台收入最优定价”; 上游数据供应者之间如何分配收入不在核心模型内.

研究问题

在有限训练预算下，如何更早发现高质量的增强-模型组合？

研究对象

外部数据增强与机器学习模型的联合搜索。

核心比较

Data-Bandit、Data-All、Data-Alt 与 AutoML。

评价维度

- 搜索时间—效用曲线
- 最终效用
- 识别出的增强数量

算法步骤

- ① 增强层提出候选 T_i ;
- ② 按 Exp3 概率抽取一个模型 M_i ;
- ③ 只训练 $M_i \leftarrow (D_{\text{in}} \bowtie T_i)$, 得到奖励 r_i ;
- ④ 用重要性加权 $r_i/p_i(M_i)$ 更新模型权重.

训练预算

与其在一个增强上花 $|\mathcal{M}|$ 次训练测透, 不如先花 1 次快速筛选, 从而把预算用于更多增强.

比较方法


- Data-Bandit: 每轮抽一个模型
- Data-All: 每个增强训练全部模型
- Data-Alt: 固定低成本模型筛增强, 周期性完整搜模型
- AutoML: 只搜模型, 不加入外部数据

选择依据

增强不断改变输入数据, 模型奖励并非固定分布; Exp3 适合这种非平稳/对抗式反馈.

原论文设置

- 69K 个 NYC Open Data 数据集
- 约 30M 列、3B 行
- 1000 个分类/回归任务
- Random Forest、XGBoost、Neural Network 等
- 横轴：搜索时间；纵轴：效用



原文 Figure 3: 横轴为搜索时间，纵轴为效用。

分类任务

- Data-Bandit 平均效用超过 0.85
- 次优方法平均效用略高于 0.70
- AutoML 约为 0.55

回归任务

- Data-Bandit 在固定时间点均高于基线
- 多数任务识别出的增强数少于 10
- 结论：更高的有限时间发现效率

原文结论

Data-Bandit 在相同搜索时间下更快获得高质量增强-模型组合.

数据与搜索空间

- 红/白葡萄酒，分类与回归各 30 个任务
- 2 个基础特征 + 9 个外部增强
- 6 个自包含模型族
- 每种方法最多 60 次模型训练
- 固定种子；每任务 60/20/20 划分


数据划分

- 训练集：排序增强候选、拟合模型
- 验证集：搜索与选择当前 incumbent
- 测试集：只报告验证选择方案的效用

复现边界

NYC 数据池、Metam 配置和完整代码未公开；
这里复现预算语义和定性现象，不逐点还原原图时间轴。

RQ1: 复现实验结果



发现结果

- Data-Bandit 前期效用曲线上升较快
- 分类任务中平均效用超过 0.85
- 多数任务识别出的增强数少于 10

数据落盘: results/tables/rq1_task_results.csv, rq1_paired_comparisons.csv, results/rq1_summary.json.

结果边界

- 60 次预算终点仍是 Data-All 略高
- Data-Bandit 与 Data-Alt 在本设置下表现可比

研究问题

平台未知买家类型先验时，能否仅凭停止轮次学习真实分布 μ^* ？

观测变量

买家在给定价格曲线与搜索过程下的停止轮次 Y .

评价指标

- $D_{\text{KL}}(\mu^* \parallel \mu^{(t)})$
- 学习率对收敛速度的影响
- 批量对估计稳定性的影响

识别条件

不同买家类型必须产生可区分的停止分布.

算法步骤

- ① 对每类 θ_i 预计算停止似然

$$L_i(y) = \Pr(Y = y \mid \theta_i, x);$$

- ② 观察停止轮次 $y^{(t)}$ 后做 Bayes 更新

$$w_i^{(t)} = \frac{L_i(y^{(t)})\mu_i^{(t)}}{\sum_j L_j(y^{(t)})\mu_j^{(t)}};$$

- ③ 用学习率平滑

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t \bar{w}^{(t)}.$$

比较维度

- 真实先验 μ^* 的收敛性
- 学习率与收敛速度、波动
- 批量与估计稳定性

理论前提

不同类型必须产生可区分的停止分布；
否则只看停止轮次不可能区分它们。

原论文设置

- $|Q| = 10$, 类型数 $n = 5$, $T = 15$
- 5 种先验: 随机、均匀、略偏、高偏、极偏
- 学习率: $1/(t+1)$ 、 $1/\sqrt{t}$ 、 $1/2$
- 批量: 10 与 100
- 指标: $D_{\text{KL}}(\mu^* \parallel \mu^{(t)})$




Figure 5: (a) $b = 100$, 1000 轮; (b) $b = 10$, 10000 轮; (c) $b = 100$, 10000 轮.

收敛结果

- KL 散度随学习轮次下降
- $1/\sqrt{t}$ 与 $1/2$ 收敛较快
- $1/(t+1)$ 收敛较慢但更平稳

批量效应

- 批量 100 的曲线更平滑
- 批量 10 的常数学习率波动更大
- 结果支持速度-稳定性权衡

原文结论

学习率与批量共同决定先验学习的收敛速度和稳定性.

环境与似然

- 10 个质量状态、最长 15 轮
- 转移: 52% 停留、34% 升一级、14% 升两级
- 精确前向 DP 计算停止似然
- 五类估值 + 发现成本 0.018


实验组合

- 平均停止轮次: 1.0、4.0、7.2、10.2、12.6
- 最小成对 L_1 距离约 0.656
- 5 种先验 $\times$ 3 种学习率
- 批量 10/100、5 个种子、1000 轮
- 共 150 条学习运行

可识别性控制

如果五类停止分布重合, 学习失败可能只是不可识别, 而不是 Algorithm 1 本身的问题.

RQ3: 复现实验结果



随机先验，批量 100

- 最终 KL ($1/(t+1)$, $1/\sqrt{t}$, $1/2$): 0.05185、0.00798、0.00702
- $1/2$ 最快，但尾部波动 0.00358
- $1/\sqrt{t}$ 的尾部波动仅 0.00032

结果解释

- $1/(t+1)$: 最稳，但过早变得保守
- $1/2$: 快，但持续受批次噪声影响
- $1/\sqrt{t}$: 速度-稳定性折中
- 批量 10 + 常数率时明显失稳

数据落盘: results/tables/rq3_paper_reproduction.csv、rq3_paper_summary.csv、
results/paper_experiments_summary.json.

核心问题

联合定价 MILP 相比传统基线能多收多少收入？IS 上训练的价格能否泛化到 OOS 新轨迹？

Q1: MILP 是否优于简单方法？

- 与 **Independent**、**Shift**、**Jiggle** 比较
- 评估跨质量联合定价的收入增量

Q2: 最优价格能否泛化？

- IS 训练的价格 → OOS 测试
- 模拟真实部署中的分布外表现

说明

本复现为**透明缩减设置**，非点对点复制。原文 School 数据任务和完整代码未公开，使用自包含合成数据。

任务规格

- 10 个随机重复任务
- 4 个离散质量状态
- 6 个异质买家类型
- 估值单调但增长率不同

数据集与归一化

- IS 训练：100 条全质量可达轨迹
- OOS 测试：4,000 条 Markov 随机轨迹
- 收入归一化：除以零价格期望福利

RQ2: 复现实现思路

- ① **合成市场构造**: `synthetic_instance(seed)` 生成估值矩阵、Markov 转移矩阵与先验分布.
- ② **轨迹生成**: IS 轨迹确定性构造; OOS 轨迹由 `simulate_markov_trajectories` 随机采样.
- ③ **定价方法**: MILP 调用 HiGHS, Big-M 线性化 $y = x \cdot z$, bitmask 压缩相同 availability set. Independent / Shift / Jiggle 用估值网格穷举或局部搜索.
- ④ **收入评估**: 每种价格 $\times$ IS/OOS $\times$ forced/realized 共 4 个指标, 10 次重复取 **均值 $\pm$ 标准误**.

RQ2: 五种定价方法

方法	来源	思路
MILP (IS)	Theorem 4.2	IS 轨迹上求解联合定价 MILP, 最大化经验期望收入.
Independent	Appendix D.1	逐质量垄断定价, 忽略跨质量替代效应.
Shift	Appendix D.1	从 Independent 出发, 统一偏移所有质量的价格.
Jiggle	Appendix D.1	从 Shift 初始解做贪心局部搜索直至收敛.
OOS-MILP	参考上界	直接使用 OOS 轨迹训练的 MILP, 衡量 IS 信息损失.

排序预期: $\text{Independent} \leq \text{Shift} \leq \text{Jiggle}$ (不劣性链, Appendix D.1)

RQ2: 同一个 MILP, 两种评价指标

Forced-choice (论文指标)

- 买家必须选择模型
- 即使净效用为负也必须买
- → MILP 直接优化的目标

IS 归一化收入: 0.7926

Realized (自愿购买)


- 买家有不购买选项
- 净效用为负 → 退出
- → 真实市场可实现的收入

OOS 实现收入: 0.4075

关键差异

从 0.79 跌到 0.41——近一半收入因买家退出而消失. 评价语义的选择会根本性地改变方法排序.

RQ2: Forced-choice 指标结果



方法排序（符合论文预期）

方法	归一化收入
MILP (IS)	0.7926 ± 0.0098
OOS-MILP	0.7898
Jiggle	0.6353
Shift	0.6157
Independent	0.4880

结论： MILP 捕获约 79% 零价格福利；
原文 Fig. 4 约 85%，差距合理。不劣性
链成立。

OOS Realized 收入排序

方法	归一化收入
Independent	0.5468 $\pm$ 0.0119
IS MILP	0.4075 $\pm$ 0.0138
Shift	$\sim$ 0.38
Jiggle	$\sim$ 0.38

为什么 Independent 反而最好？

- 逐质量独立定价，不推高整体价格曲线
- MILP 统一定高价收割高估值买家 $\rightarrow$ 有退出后大量流失

正确解读：不是 Independent 普遍最优，而是论文优化目标 $\neq$ 真实购买行为，两者之间存在语义边界。

我们把论文理论整理为一条机制链和四个可检验结论

统一机制链

- ① 发现引擎生成性能轨迹；
- ② 买方按阈值规则选择停止；
- ③ 平台把最优响应写入 MILP；
- ④ 新行为继续更新价格与先验。

四个可检验结论

- 停止策略可在多项式时间计算；
- 平台价格可由标准求解器获得；
- 有限轨迹可学习近优价格；
- 估计误差只造成线性级损失。

总结

我们明确了每个理论模块的输入、输出、核心结论和成立假设，便于后续实现与改进逐项核对。

Q&A

- [1] Minbiao Han, Jonathan Light, Steven Xia, Sainyam Galhotra, Raul Castro Fernandez, and Haifeng Xu.
Optimal pricing for data-augmented automl marketplaces.
arXiv preprint arXiv:2310.17843, 2025.
Version 2, May 27, 2025.
- [2] Martin L. Weitzman.
Optimal search for the best alternative.
Econometrica, 47(3):641–654, 1979.
- [3] Sainyam Galhotra et al.
Metam: Goal-oriented data discovery.
In *Proceedings of the 2023 ACM SIGMOD International Conference on Management of Data*, 2023.

