

数据增强 AutoML 市场中的最优定价

论文理论解读 · 实验复现 · 机制讨论

张博渊、林润铎、彭博宇

数据要素市场课程 · 中期答辩

参考论文: *Optimal Pricing for Data-Augmented AutoML Marketplaces*

2026 年 7 月 18 日



- 1 研究问题
- 2 机制与结论
- 3 RQ1: 增强-模型发现
- 4 RQ3: 先验学习
- 5 RQ2: 联合定价 MILP 的收入评估
- 6 改进方案



机制重构


将分散在论文各节的模型整理为**轨迹**、**停止**、**定价**、**学习**四个环节。

结论提炼

从 DP、MILP 与学习理论中提炼四条可直接解释和检验的结论。

边界识别

明确结论成立所需的性能动态、买方偏好与信息条件。



第 1 部分

研究问题



数据本身值多少钱不是主要问题，而是模型增益值多少钱

直接售卖数据的错配

- 数据价值**依赖具体任务**，买方事前难判断是否有用；
- AutoML 按计算时间收费，买方可能为**无效搜索**承担成本；
- 不同买方对同一性能提升有不同支付意愿。

论文的定价对象

$$\Delta q = q(C \leftarrow D \bowtie A) - q(C_0 \leftarrow D)$$

数据增强与模型搜索共同产生的**工具性价值**

机制载体

平台预先公布统一价格曲线 $x(q)$ ，按买方最终购买的性能档位收费。


第 2 部分

机制与结论



平台把数据发现、模型搜索与定价接成一个闭环

- 买方提交任务、初始训练数据和评估方式；平台从外部数据池中搜索增广特征与模型。
- 发现引擎持续输出性能轨迹，定价引擎将其转换为“性能-价格”菜单。



公开价格曲线同时处理性能、偏好与搜索成本

符号	在机制中的作用
$\mathcal{Q}, q_t$	离散化的模型性能集合与当前观测性能.
$P^t(q' q)$	性能从本期到下一期的搜索动态.
c, T	每期真实搜索成本与最长搜索期数.
$\theta \sim \mu$	买方类型及其先验; $v^\theta(q)$ 表示对性能的价值.
$x(q)$	平台面向所有买方公开的性能价格.

买方只比较一件事

$$\text{净效用} = \text{性能价值} - \text{价格} - \text{搜索成本}$$

买方通过停止时点表达自己的支付意愿

1. 进入前

平台公开价格、成本与性能演化信息.

2. 搜索中

每期看到最新性能, 保留已经出现的优质档位.

3. 自主决策

比较立即停止与继续搜索的期望收益.


4. 退出或购买

选择历史上净效用最高的档位, 也可以不购买.

机制性质

平台不要求买方主动报告类型; 不同支付意愿通过**停止时点与购买档位**自然表现出来.

结论 1: 买方遵循“立即停止还是继续搜索”的阈值规则



这是相关收益的 Pandora's Box

- 下一期性能依赖当前 q_t ;
- 决策需要记住历史最佳净效用;
- 搜索存在有限期限与逐期成本.

结论

若**立即停止效用**不低于**继续搜索的期望效用**, 买方停止; 否则继续.

结论 2: 三个状态量足以计算买方的最优停止

历史最好 q_1

到目前为止，净效用最高的性能档位.

当前性能 q_2

决定下一期性能的条件分布.

当前时间 t

决定剩余期限与累计搜索成本.

命题 4.1 的结论

动态规划只需遍历 $|Q|^2 T$ 个状态，最优停止策略可在 $O(|Q|^2 T)$ 时间内求得.
平台无需枚举所有搜索历史，只需维护这三个状态量，就能预测买方的最优响应.

结论 3：把买方选择写入 MILP，平台价格即可计算

原问题是双层优化

- 平台先选择价格曲线；
- 买方随后选择净效用最高的档位；
- 平台收入取决于买方的离散选择。

MILP 的转写思路

- x 表示公开价格；
- z 表示买方选择哪个档位；
- a 记录最大净效用；
- y 记录该选择带来的实际收入。

结论

通过 Big- M 约束把“买方最优选择”和“平台收入”同时编码后，可直接用标准 MILP 求解器输出整条价格曲线。

结论 4：有限轨迹足以学习近优价格

定理 4.2 及其结论

在买方价值有界、发现成本相对价值可忽略时，只要样本量满足

$$m \geq \frac{b^2}{2\varepsilon^2} \ln \frac{2}{\delta},$$

学到的价格曲线以至少 $1 - 2\delta$ 的概率达到距最优收入不超过 ε 的水平。

精度代价

ε 减半，所需样本量约增至四倍。

数据要求

只需采样真实性能轨迹，不必写出完整转移矩阵。

机制含义

价格曲线不仅可计算，而且能从有限历史任务中学习。

停止行为既能学习买方先验，也限制估计误差的损失

先验如何学习

- ① 观察买方在什么性能与时间停止；
- ② 比较不同类型产生该行为的可能性；
- ③ 反复交互后更新类型分布。

定理 5.2 的结论

若买方先验 μ 与性能动态 P 的估计误差均为 ε 量级，则平台收入损失仅为

$$O(\varepsilon).$$

前提

不同买方类型必须在某些价格下产生可区分的停止分布，否则仅凭行为无法识别类型。

发现引擎每轮只训练一个模型，持续输出可定价轨迹

为什么不能穷举

增广子集与模型的组合数量快速膨胀；每轮测试全部模型会让搜索成本无法接受。

联合发现算法

- ① 用 Metam 聚类并选择候选增广；
- ② 将模型视作 Exp3 的不同臂；
- ③ 每轮只采样并训练**一个模型**；
- ④ 用当前性能更新模型权重。

与定价机制的接口

算法具备 anytime 性质：每轮输出一个 q_t ，买方可随时停止；性能序列正是停止策略与价格学习所需的轨迹。

四条建模边界决定理论结论能否成立

- ① **性能动态**: Q 有限离散, 未来性能只依赖当前性能与时间; 动态可公开或估计.
- ② **买方偏好**: 类型空间有限、价值有界; 不同类型的停止行为具有可识别性.
- ③ **价格形式**: 平台对所有买方公布同一条按性能收费的价格曲线, 不依赖主动报告.
- ④ **计算假设**: PAC 保证要求发现成本相对价值可忽略; 一般误差的收入影响由鲁棒性结论控制.

范围边界

论文主要解决“买方停止决策 + 平台收入最优定价”; 上游数据供应者之间如何分配收入不在核心模型内.

第 3 部分

RQ1: 增强-模型发现



研究问题

在有限训练预算下，如何更早发现高质量的增强-模型组合？

研究对象

外部数据增强与机器学习模型的联合搜索。

核心比较

Data-Bandit、Data-All、Data-Alt 与 AutoML。

评价维度

- 搜索时间—效用曲线
- 最终效用
- 识别出的增强数量

算法步骤

- ① 增强层提出候选 T_i ;
- ② 按 Exp3 概率抽取一个模型 M_i ;
- ③ 只训练 $M_i \leftarrow (D_{\text{in}} \bowtie T_i)$, 得到奖励 r_i ;
- ④ 用重要性加权 $r_i/p_i(M_i)$ 更新模型权重.

训练预算

Data-All 在一个增强上训练全部 $|\mathcal{M}|$ 个模型;
Data-Bandit 每轮只抽取并训练 1 个模型, 用较低单轮成本把预算用于更多增强候选.

比较方法

- Data-Bandit: 每轮抽一个模型
- Data-All: 每个增强训练全部模型
- Data-Alt: 固定低成本模型筛增强, 周期性完整搜模型
- AutoML: 只搜模型, 不加入外部数据

选择依据

增强不断改变输入数据, 模型奖励并非固定分布

原论文设置

- 69K 个 NYC Open Data 数据集
- 约 30M 列、3B 行
- 1000 个分类/回归任务
- Random Forest、XGBoost、Neural Network 等
- 横轴：搜索时间；纵轴：效用




Figure 3: Compare discovery techniques on 1K input tasks.

结论

Data-Bandit 在相同搜索时间下更快获得高质量增强-模型组合.

数据与搜索空间


- UCI Wine Quality 数据, 分类与回归各 30 个任务
- 2 个基础特征 + 9 个外部增强
- 6 个简单候选模型: 线性/二次/随机 ReLU Ridge

发现结果

- Data-Bandit 前期效用曲线上升较快
- 同时由于模型简单, Alt 的效用也不错

复现边界

NYC 数据池、Metam 配置和完整代码未公开; Random Forest 等模型耗时较长



第 4 部分

RQ3: 先验学习



研究问题

平台未知买家类型先验时，能否仅凭停止轮次学习真实分布 μ^* ?

观测变量

买家在给定价格曲线与搜索过程下的停止轮次 Y .

评价指标

- $D_{\text{KL}}(\mu^* \parallel \mu^{(t)})$
- 学习率对收敛速度的影响
- 批量对估计稳定性的影响

识别条件

观察不同买家类型产生可区分的停止分布

算法步骤

- ① 对每类 θ_i 预计算停止似然

$$L_i(y) = \Pr(Y = y \mid \theta_i, x);$$

- ② 观察停止轮次 $y^{(t)}$ 后做 Bayes 更新

$$w_i^{(t)} = \frac{L_i(y^{(t)})\mu_i^{(t)}}{\sum_j L_j(y^{(t)})\mu_j^{(t)}};$$

- ③ 用学习率平滑

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t \bar{w}^{(t)}.$$

比较维度

- 真实先验 μ^* 的收敛性
- 学习率与收敛速度、波动
- 批量与估计稳定性

理论前提

不同类型必须产生可区分的停止分布；
否则只看停止轮次不可能区分它们。

RQ3: 原文实验设计






Figure 5: 固定 $\eta_t = 1/\sqrt{t}$; (a) $b = 100, N = 1000$, (b) $b = 10, N = 10000$, (c) $b = 100, N = 10000$.


论文模拟场景与设置

- 性能档位 $\mathcal{Q} = \{100\%, \dots, 91\%\}$ 、搜索期限 $T = 15$ ；真实先验 μ^* 随机生成
- 平台不观察买方类型，只观察其**停止轮次**，据此学习 μ^*
- 正文 Figure 5 固定 $\eta_t = 1/\sqrt{t}$ ，比较 $b = 10/100$ 与学习轮数 N
- 另外 $1/2$ 和 $1/(t+1)$ 两种学习率见附录 Figure 6–7

结果分析

- KL 散度随学习轮次下降
- Figure 5(b)(c): 同为 $N = 10000$, $b = 100$ 比 $b = 10$ 平滑
- 较激进学习率收敛更快，但波动更大

RQ3 reduced reproduction: random prior



复现设置

- 10 个质量状态、5 类估值、 $T = 15$ ；自行设定转移概率与成本
- 固定随机生成的五类买方占比；平台从均匀估计出发，初始 KL 为 0.2836
- 三种学习率、批量 10/100、5 个观测种子
- 前向 DP 计算似然

复现结果分析

- (a) 最终 KL: 0.12083、0.01926、0.00495
- (b)(c) 同为 $N = 10000$: $b = 100$ 的收敛更平滑
- $1/(t+1)$ 最稳定但收敛慢； $1/2$ 前期快但振荡
- $1/\sqrt{t}$ 在大批量下兼顾下降速度与稳定性
- 原文未公开具体估值、转移过程、随机种子与代码

第 5 部分

RQ2: 联合定价 MILP 的收入评估



核心问题

联合定价 MILP 相比传统基线能多收多少收入？IS 上训练的价格能否泛化到 OOS 新轨迹？

Q1: MILP 是否优于简单方法？

- 与 **Independent**、**Shift**、**Jiggle** 比较
- 评估跨质量联合定价的收入增量

Q2: 最优价格能否泛化？

- IS 训练的价格 → OOS 测试
- 模拟真实部署中的分布外表现

说明

本复现为**透明缩减设置**，非点对点复制。原文 School 数据任务和完整代码未公开，使用自包含合成数据。

任务规格

- 10 个随机重复任务
- 4 个离散质量状态
- 6 个异质买家类型
- 估值单调但增长率不同

数据集与归一化

- IS 训练：100 条全质量可达轨迹
- OOS 测试：4,000 条 Markov 随机轨迹
- 收入归一化：除以零价格期望福利

复现实现思路：四层架构，数据全部程序化生成

- ① **合成市场构造**: `synthetic_instance(seed)` 生成估值矩阵、Markov 转移矩阵与先验分布. 全部硬编码 + 固定 seed, 零外部数据依赖.
- ② **轨迹生成**: IS 轨迹由 `np.tile([0,1,2,3], (100,1))` 确定性构造; OOS 轨迹由 `simulate_markov_trajectories` 随机采样 4,000 条.
- ③ **定价方法**: MILP 调用 HiGHS, Big-M 线性化 $y = x \cdot z$, bitmask 压缩相同 availability set. Independent / Shift / Jiggle 用估值网格穷举或局部搜索.
- ④ **收入评估**: 每种价格 $\times$ IS/OOS $\times$ forced/realized 共 4 个指标, 10 次重复取 **均值 $\pm$ 标准误差**.

五种定价方法

方法	来源	思路
MILP (IS)	Theorem 4.2	IS 轨迹上求解联合定价 MILP，最大化经验期望收入.
Independent	Appendix D.1	逐质量垄断定价，忽略跨质量替代效应.
Shift	Appendix D.1	从 Independent 出发，统一偏移所有质量的价格.
Jiggle	Appendix D.1	从 Shift 初始解做贪心局部搜索直至收敛.
OOS-MILP	参考上界	直接使用 OOS 轨迹训练的 MILP，衡量 IS 信息损失.

排序预期： $\text{Independent} \leq \text{Shift} \leq \text{Jiggle}$ （不劣性链，Appendix D.1）

同一个 MILP，两种评价指标

Forced-choice（论文指标）

- 买家必须选择模型
- 即使净效用为负也必须买
- → MILP 直接优化的目标

IS 归一化收入：0.7926

Realized（自愿购买）


- 买家有不购买选项
- 净效用为负 → 退出
- → 真实市场可实现的收入

OOS 实现收入：0.4075

关键差异

从 0.79 跌到 0.41——近一半收入因买家退出而消失。评价语义的选择会根本性地改变方法排序。这不是论文错了，而是理解本文最重要的 nuance。

核心数值结果：Forced-choice 指标



方法排序（符合论文预期）

方法	归一化收入
MILP (IS)	0.7926 ± 0.0098
OOS-Informed MILP	0.7898
Jiggle	0.6353
Shift	0.6157
Independent	0.4880

结论： MILP 捕获约 79% 零价格福利；原文 Fig. 4 约 85%，差距合理。不劣性链成立。

核心数值结果：自愿购买指标——排序翻转

OOS Realized 收入排序

方法	归一化收入
Independent	0.5468 $\pm$ 0.0119
IS MILP	0.4075 $\pm$ 0.0138
Shift	~ 0.38
Jiggle	~ 0.38

为什么 Independent 反而最好？

- 逐质量独立定价，不推高整体价格曲线
- MILP 统一定高价收割高估值买家 $\rightarrow$ 有退出后大量流失

正确解读：不是 Independent 普遍最优，而是论文优化目标 $\neq$ 真实购买行为，两者之间存在语义边界。

第 6 部分

改进方案



复现中发现的四个机制问题

- ① **强制购买不现实**. 论文 MILP 约束每个买家必须购买. 实验显示: 加入退出选项后, 论文最优价格的实际收入从 0.79 跌至 0.41——近一半收入消失, 方法排序完全翻转.
- ② **冷启动矛盾**. 定价需要已知买家分布 μ , 但 μ 又需要多轮交易才能学到——第一轮价格凭什么最优?
- ③ **搜索成本被忽略**. 定理 4.2 假设 $c \approx 0$. 但 $c > 0$ 时买家会更早停止、看到更少选项, 最优价格应与搜索成本耦合.
- ④ **定价与发现过程脱节**. 论文把“发现什么增强”和“怎么定价”当作独立模块. 但发现引擎的轨迹分布直接影响买家选择——平台应根据定价目标引导发现方向.

四个改进方向

改进	思路
IR-aware 定价	把退出权利写进 MILP 目标函数，定价时就考虑“买家可以不买”。代码已有原型。
鲁棒定价	分布鲁棒优化，让价格在最坏先验下也有保障，随数据增多逐步收敛。
成本感知定价	解除 $c \approx 0$ 假设，推导搜索成本非零时的修正 MILP。精确 Markov 评估器已就绪。
定价引导发现	把价格信号反馈给 Data-Bandit，优先探索高收入潜力的增强方向。

预期贡献

从“强制购买、先验已知、成本忽略、发现定价割裂”的理想模型，推向更贴近真实市场的完整机制。

- [1] Minbiao Han, Jonathan Light, Steven Xia, Sainyam Galhotra, Raul Castro Fernandez, and Haifeng Xu.
Optimal pricing for data-augmented automl marketplaces.
arXiv preprint arXiv:2310.17843, 2025.
Version 2, May 27, 2025.
- [2] Martin L. Weitzman.
Optimal search for the best alternative.
Econometrica, 47(3):641–654, 1979.
- [3] Sainyam Galhotra et al.
Metam: Goal-oriented data discovery.
In *Proceedings of the 2023 ACM SIGMOD International Conference on Management of Data*, 2023.

