

《Optimal Pricing for Data-Augmented AutoML Marketplaces》

RQ1 与 RQ3 中期汇报个人讲义

课程大作业 C.3 · 实验复现部分

2026 年 7 月 17 日

摘要

本文只服务于中期汇报中负责 RQ1 和 RQ3 的同学。RQ1 研究平台能否以较少模型训练找到高质量的“数据增强-模型”组合，对应论文 Algorithm 2 的 Data-Bandit；RQ3 研究平台能否从买家的停止轮次学习未知类型先验，对应 Algorithm 1 的平滑贝叶斯学习，并依赖 Algorithm 3 的最优停止行为。本讲义依次解释研究问题、算法直觉与公式、原论文实验、项目缩减复现、指标和结果解读，最后给出讲述顺序、常见追问与准确回答。原文 Figure 3/5 与本项目结果必须分开表述：前者来自论文，后者分别使用公开 UCI 数据和透明合成环境，目标是复现算法语义和定性现象，不是逐点还原原图。

目录

1 先把两项 RQ 放回整篇论文	3
2 RQ1: 能否高效发现增强-模型组合	3
2.1 研究问题究竟在问什么	3
2.2 Algorithm 2: Data-Bandit 的两层结构	3
2.3 为什么是 Exp3	4
2.4 四种方法一定要区分清楚	4
2.5 原论文 RQ1 实验与结论	4
2.6 本项目怎样缩减复现 RQ1	5
2.7 四个指标怎么读	5
2.8 复现结果及准确解读	6
2.9 RQ1 代码与复现入口	7
3 RQ3: 能否从停止时间学习买家先验	7
3.1 为什么停止时间包含类型信息	7
3.2 Algorithm 1 的两阶段结构	7
3.3 三种学习率为什么表现不同	8
3.4 可识别性: RQ3 最重要的前提	8

目录	2
3.5 KL 散度怎样衡量学习误差	8
3.6 原论文 RQ3 实验与结论	8
3.7 本项目怎样缩减复现 RQ3	9
3.8 复现结果及准确解读	10
3.9 RQ3 代码与复现入口	10
4 上台时怎样把两部分串起来	11
5 建议的 7-8 分钟讲述稿	11
6 老师可能追问什么	12
7 最终记忆卡片	13

1 先把两项 RQ 放回整篇论文

论文市场包含四个连续环节：

外部数据增强与模型发现 $\rightarrow$ 性能轨迹 $(q_1, \dots, q_T) \rightarrow$ 买家停止/购买 $\rightarrow$ 平台学习并更新价格。

表 1: RQ、问题、算法和实验之间的对应关系。

	研究问题	对应算法	实验回答方式
RQ1	能否快速找到高质量的数据增强-模型组合？	Algorithm 2: Metam 风格增强搜索 + Exp3 模型选择	比较 Data-Bandit、Data-All、Data-Alt、AutoML 的效用-预算曲线
RQ3	能否仅从停止时间学到真实买家类型分布？	Algorithm 1: 停止似然、Bayes 后验、学习率平滑；Algorithm 3 提供停止行为	比较不同先验、学习率和批量下的 KL 收敛速度与波动

一句话结论

RQ1 解决“平台怎样产生好的性能轨迹”，RQ3 解决“平台怎样利用买家在轨迹上的停止行为学习市场”。RQ1 提供轨迹，最优停止产生观测，RQ3 再从观测反推买家分布。

2 RQ1：能否高效发现增强-模型组合

2.1 研究问题究竟在问什么

假设平台有候选增强集合 $\mathcal{P}$ 和模型集合 $\mathcal{M}$ 。穷举所有增强子集和模型，需要训练

$$O(2^{|\mathcal{P}|} |\mathcal{M}|)$$

个模型。即使用 Metam 等方法把增强搜索缩减到 $O(\log |\mathcal{P}|)$ 轮，如果每轮仍训练全部 $|\mathcal{M}|$ 个模型，训练数仍是 $O(|\mathcal{M}| \log |\mathcal{P}|)$ 。因此 RQ1 同时问：固定预算下谁更早找到高效用组合、达到接近 oracle 的性能需要多少训练，以及少训练是否牺牲最终性能。

直觉

如果一次增强有六个模型，Data-All 会立即花六次训练把这个增强测透；Data-Bandit 先花一次训练判断它是否值得继续。省下来的预算可以探索更多增强。它优化的是**搜索过程中的样本效率**，不是承诺每个有限预算终点都严格优于穷举。

2.2 Algorithm 2: Data-Bandit 的两层结构

Algorithm 2 把“选增强”和“选模型”拆成两层：增强层从外部数据中提出当前最值得测试的增强 T_i ；模型层把每个 $M \in \mathcal{M}$ 看作 Exp3 的一只臂，每轮只抽取一只臂训练。

设模型权重为 $w_i(M)$ 、探索系数为 γ ，第 i 轮抽模型的概率为

$$p_i(M) = (1 - \gamma) \frac{w_i(M)}{\sum_{M'} w_i(M')} + \frac{\gamma}{|\mathcal{M}|}. \quad (1)$$

第一项偏向历史表现好的模型，第二项保证每个模型至少有 $\gamma/|\mathcal{M}|$ 的探索概率。抽到 M_i 后，在 $D_{\text{in}} \bowtie T_i$ 上训练并得到奖励 $r_i \in [0, 1]$ 。由于只观察被抽中模型，使用重要性加权

$$\hat{r}_i(M_i) = \frac{r_i}{p_i(M_i)},$$

再更新

$$w_{i+1}(M_i) = w_i(M_i) \exp\left(\frac{\gamma \hat{r}_i(M_i)}{|\mathcal{M}|}\right). \quad (2)$$

直觉

若一个模型被很小概率抽到却取得高奖励， $r_i/p_i(M_i)$ 会较大，系统会迅速提高其权重。这个校正让“只观察一只臂”仍能纠正不同模型被观察频率不同造成的偏差。

2.3 为什么是 Exp3

每轮输入数据因增强 T_i 改变，同一模型的奖励分布并非固定不变。原文将其视为更接近对抗式 bandit 的环境；Exp3 不依赖固定随机奖励分布，并通过显式探索处理变化的数据。算法还具有 anytime 性质：每轮都产生当前性能 q_i ，买家可以随时停止，正好与论文的停止定价机制衔接。

2.4 四种方法一定要区分清楚

Data-Bandit 每个增强只抽样训练一个模型，用 Exp3 更新模型权重。

Data-All 对每个候选增强训练全部模型；单个增强判断充分，但预算消耗最快。

Data-Alt 原文固定一个高效低成本模型测试增强，并周期性在当前最佳增强上运行 AutoML。项目中用固定线性模型筛增强，每三个增强周期性测试全部六个模型，保留相同预算语义。

AutoML 不搜索外部数据，只在原始输入数据上搜索模型。

2.5 原论文 RQ1 实验与结论

原文使用约 69K 个 NYC Open Data 数据集组成的数据池，约含 30M 列、3B 行；在 1000 个分类/回归输入任务上平均。例子包括学校考试成绩预测和交通碰撞数量预测。模型库包含 Random Forest、XGBoost、Neural Network 等。




图 1: 原论文 Figure 3 的图像部分。横轴是搜索时间，纵轴是效用；右图还报告增强数量。

原文报告：分类上 Data-Bandit 平均效用超过 0.85，次优基线略高于 0.7，AutoML 约 0.55；回归上在固定搜索时间点，Data-Bandit 也高于基线；大多数任务使用的增强数少于 10。

汇报边界

原文图的横轴是秒，依赖机器、TPOT 和 NYC 数据池；本项目图的横轴是模型训练次数。两者都刻画搜索成本，但不能把本项目数字与原文时间轴逐点比较。

2.6 本项目怎样缩减复现 RQ1

原始 NYC 任务、Metam 配置和完整代码不可得，因此项目使用公开 UCI Wine Quality 构造可连接增强任务：

- 红/白葡萄酒各做 15 次固定种子重复；分类与回归分别 30 个任务，共 60 个任务；
- 每个任务抽取 1200 条记录，按 60%/20%/20% 分为训练、验证和测试；
- 前两个特征作为基础数据，其余九个特征依训练集相关性排序，逐个作为外部增强加入；
- 分类目标是质量是否至少为 6，效用为准确率；回归效用为

$$U = \frac{1}{1 + \text{RMSE}/\text{Std}(y)};$$

- 六个模型为四种正则强度的线性模型、二次特征模型和随机 ReLU 特征模型；
- 每种方法最多允许 60 次模型训练；验证集负责搜索，测试集只报告由验证集选出的 incumbent，避免测试泄漏。

2.7 四个指标怎么读

令第 b 次训练后当前最好方案的测试效用为 U_b ，总预算为 $B = 60$ 。

1. **最终效用** U_B : 回答“预算全部用完后谁最好”。

2. **发现曲线 AUC**:

$$\text{AUC} = \frac{1}{B} \sum_{b=1}^B U_b.$$

项目输出字段沿用 `normalized_auc`；“归一化”指除以预算长度，不是除以 oracle。它回答“整个搜索过程中谁更早找到好方案”。

3. **达到 95% oracle 增益所需训练数**: 令基础效用为 U_0 、验证选择 oracle 的测试效用为 U^* ，目标阈值是

$$U_0 + 0.95 \max\{0, U^* - U_0\}.$$

首次达到阈值的训练次数越少越好；未达到记为 $B + 1 = 61$ 。

4. **配对 bootstrap 区间**: 同一个任务上计算 Bandit 与基线的 AUC 差，再对任务重采样。区间不跨 0 才支持平均差异显著不为 0。

2.8 复现结果及准确解读




图 2: RQ1 缩减复现。前两图为分类/回归 incumbent 测试效用，第三图为达到 95% oracle 增益所需训练数。

表 2: Data-Bandit 相比 Data-All 的核心结果。

任务	AUC 配对差	95% bootstrap 区间	95% 增益训练节省
分类	+0.00794	[0.00340, 0.01220]	30.3%
回归	+0.00335	[0.00185, 0.00481]	27.5%

正确结论分三层:

1. **搜索过程更高效**: Bandit 相比 Data-All 的 AUC 配对区间均不跨 0，并以更少训练达到 95% oracle 增益。
2. **完整预算终点不是 Bandit 最好**: 分类终点为 Data-All 0.74083、Bandit 0.73931；回归为 0.54715、0.54590，差距约 0.0012–0.0015。

3. 对 **Data-Alt** 只能说相当：分类/回归 AUC 差的区间都跨 0，不能声称 Bandit 显著更优。

一句话结论

RQ1 复现支持 “Data-Bandit 更早找到接近 oracle 的方案”，但不支持 “任意预算和任意基线下都最好”。这恰好体现发现算法的目标：在买家可能随时停止的市场里，提高前期搜索效率。

2.9 RQ1 代码与复现入口

- 算法与数据：src/automl_market/discovery.py
- 实验脚本：scripts/run_rq1.py
- 逐任务结果：results/tables/rq1_task_results.csv
- 配对比较：results/tables/rq1_paired_comparisons.csv

```
conda activate automl-market
make rq1
```

3 RQ3: 能否从停止时间学习买家先验

3.1 为什么停止时间包含类型信息

买家类型 θ 决定估值曲线 $v^\theta(q)$ 。面对同一价格和性能演化，高估值或更有耐心的类型可能愿意继续等待，低估值类型可能更早停止。因此停止轮次 $y \in \{1, \dots, T\}$ 是可观察的行为信号。平台看不到买家类型，但如果已知每类买家的停止时间分布，就能用 Bayes 公式反推类型概率。

直觉

把停止时间想成医学检测结果：类型是隐藏状态，停止轮次是观测。观测不直接等于类型，但不同类型产生该观测的概率不同，所以可以更新信念。

3.2 Algorithm 1 的两阶段结构

阶段一：预计算停止似然。 给定价格 x 、转移矩阵和类型 θ_i ，用最优停止 DP (Algorithm 3/Proposition 4.1) 求行为策略，再计算

$$L_i(y) = \Pr(Y = y \mid \theta_i, x), \quad y = 1, \dots, T.$$

阶段二：根据市场观测更新先验。 当前估计先验为 $\mu^{(t)}$ 。观察一位买家在 $y^{(t)}$ 停止后，类型后验为

$$w^{(t)}(\theta_i) = \frac{L_i(y^{(t)})\mu^{(t)}(\theta_i)}{\sum_j L_j(y^{(t)})\mu^{(t)}(\theta_j)}. \quad (3)$$

论文不是直接令新先验等于后验，而是平滑更新：

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t w^{(t)}. \quad (4)$$

若一轮观察 b 位买家，则先平均各自后验 $\bar{w}^{(t)} = b^{-1} \sum_{k=1}^b w_k^{(t)}$ ，再用 $\bar{w}^{(t)}$ 更新。

3.3 三种学习率为什么表现不同

表 3: 学习率的速度-稳定性含义。

学习率	行为	预期现象
$1/(t+1)$	很快衰减到接近 0	后期非常稳定，但早期误差若未纠正，之后更新能力不足
$1/\sqrt{t}$	衰减慢于调和 Learning Rate	持续吸收数据，通常兼顾收敛速度和稳定性
$1/2$	始终不衰减	对新批次反应最快，但抽样噪声一直进入估计，尾部振荡明显

批量 b 越大，平均后验中的抽样噪声越小，所以尤其能稳定常数学习率；代价是每次更新需要更多买家观测。

3.4 可识别性：RQ3 最重要的前提

若两个类型满足

$$\Pr(Y = y \mid \theta_i, x) = \Pr(Y = y \mid \theta_j, x) \quad \text{对所有 } y \text{ 和可用价格 } x,$$

那么只看停止时间无法区分它们。论文的收敛论述依赖可识别性：不同潜在类型必须能在某些卖方策略下产生不同响应。不可区分的类型只能合并为一个有效类型。

汇报边界

“Algorithm 1 一定能学到真实先验” 不准确。正确说法是：在停止似然正确、类型可识别并持续获得数据的条件下，贝叶斯学习可向真实分布集中。

3.5 KL 散度怎样衡量学习误差

项目使用

$$D_{\text{KL}}(\mu^* \parallel \mu^{(t)}) = \sum_i \mu_i^* \log \frac{\mu_i^*}{\mu_i^{(t)}}.$$

它非负，等于 0 当且仅当估计与真实分布一致。`final_kl` 衡量最后一轮误差；`tail_mean_kl` 是最后 100 轮平均；`tail_std_kl` 衡量最后 100 轮的稳定性。

3.6 原论文 RQ3 实验与结论

原文设置 $|\mathcal{Q}| = 10$ 、买家类型数 $n = 5$ 、搜索时域 $T = 15$ ，比较随机、均匀、略偏、高偏和极偏等真实先验，以及 $1/(t+1)$ 、 $1/\sqrt{t}$ 、 $1/2$ 三类学习率和批量 10/100。正文 Figure 5 重点展示随机先验与 $1/\sqrt{t}$ ，附录给出更多先验和学习率。




图 3: 原论文 Figure 5 的三个 KL 曲线面板; 正文使用学习率 $1/\sqrt{t}$ 。

作者观察到 KL 低于约 0.025 并继续下降; 更激进学习率收敛更快但不稳定; 增大批量可平滑波动。

3.7 本项目怎样缩减复现 RQ3

项目构造一个透明的有限 Markov 环境:

- 10 个质量状态, 最长 15 轮; 初始质量只落在前三档;
- 每轮以 52% 概率停留、34% 概率升一档、14% 概率升两档;
- 五类估值为 $v_i(q) = a_i\sqrt{q}$, 其中 $a_i \in \{0.20, 0.30, 0.40, 0.50, 0.55\}$; 发现成本为 0.018;
- 用最优停止 DP 的精确前向状态传播计算各类型的停止似然, 不引入 Monte Carlo 估计误差;
- 五类平均停止轮次约为 1.0、4.0、7.2、10.2、12.6, 最小成对 L_1 距离约 0.656, 显式满足可识别性;
- 5 种真实先验、3 种学习率、批量 10/100、5 个种子、1000 轮, 共 $5 \times 3 \times 2 \times 5 = 150$ 条学习运行。

3.8 复现结果及准确解读




图 4: RQ3 缩减复现: 左图为随机先验、批量 100 的平均 KL 曲线, 右图比较不同设置的最终 KL。

表 4: 随机先验、批量 100、1000 轮的关键数字 (均值 $\pm$ 标准误, 5 个种子)。

学习率	最终 KL	尾部平均 KL	尾部标准差
$1/(t+1)$	0.05185 ± 0.01235	0.05214	0.00019
$1/\sqrt{t}$	0.00798 ± 0.00316	0.00834	0.00032
$1/2$	0.00702 ± 0.00266	0.00716	0.00358

1. **只看最终点:** 常数 $1/2$ 最低, 说明它适应很快。
2. **看尾部波动:** $1/2$ 的标准差 0.00358, 约为 $1/(t+1)$ 的 19 倍, 因此不能只说它“最好”。
3. **看速度-稳定性:** $1/\sqrt{t}$ 最终误差接近常数率, 但波动小一个数量级, 是更均衡的选择。
4. **看批量:** 批量 10 时, 常数 $1/2$ 在五种先验上的平均最终 KL 约 0.1965, 尾部标准差约 0.0488, 明显比批量 100 不稳定。

一句话结论

RQ3 复现了论文的定性结论: 学习能够收敛; 激进学习率快但抖; 大批量能抑制抽样噪声。
 $1/\sqrt{t}$ 是较稳妥的折中, 但不是一个对所有市场都最优的定理。

3.9 RQ3 代码与复现入口

- 学习算法: `src/automl_market/learning.py`

- 停止 DP: `src/automl_market/market.py`
- 实验环境: `src/automl_market/paper_experiments.py`
- 逐运行结果: `results/tables/rq3_paper_reproduction.csv`

```
conda activate automl-market
make paper-experiments
```

4 上台时怎样把两部分串起来

建议用“**问题-算法-实验-边界**”四步讲每个 RQ，而不是逐条读参数：

1. RQ1 问组合太多时怎样减少训练；Algorithm 2 用增强搜索加 Exp3，每轮只训练一个模型。
2. AUC 和达到 95% oracle 的训练数显示前期更高效；但 Data-All 终点略高，对 Data-Alt 没有显著优势。
3. 转场：发现引擎产生性能轨迹，买家在轨迹上停止；停止时间本身又暴露类型信息。
4. RQ3 预计算各类停止似然，做 Bayes 后验，再用学习率平滑。
5. KL 下降说明学习有效；三种学习率展示速度-稳定性权衡；批量 100 更平滑。
6. 最后强调可识别性和缩减复现边界。

5 建议的 7-8 分钟讲述稿

RQ1 (约 3.5 分钟)

“RQ1 问的是平台能否用较少训练找到高质量的数据增强和模型组合。难点是增强集合很大，而且每个增强如果再训练全部模型，开销会乘上模型数。论文的 Algorithm 2 用两层搜索：Metam 风格方法提出增强，Exp3 把模型当作 bandit 的臂，每轮只抽一个模型训练。概率由历史权重和均匀探索组成，重要性加权奖励用来修正只观察一只臂造成的偏差。

原文在 69K 个 NYC 数据集和 1000 个任务上比较四种方法，报告 Bandit 在更短时间达到更高效用。由于数据和完整代码未公开，我们在 UCI Wine Quality 上构造 60 个公开任务，以模型训练次数作为预算。相比 Data-All，Bandit 的发现曲线 AUC 在分类和回归上分别高 0.00794 和 0.00335，配对区间不跨 0；达到 95% oracle 增益所需训练减少约 30.3% 和 27.5%。但 60 次预算终点仍是 Data-All 略高，而且 Bandit 与 Data-Alt 的区间跨 0。因此准确结论是 Bandit 更早接近最优，而不是所有指标都无条件最好。”

RQ3 (约 3.5 分钟)

“RQ3 问平台能不能从买家的停止时间学习真实类型分布。不同类型的估值不同，所以面对相同轨迹和价格会在不同轮次停止。Algorithm 1 先根据最优停止策略预计算每种类型在各轮停止的概

率，观察实际停止轮次后用 Bayes 公式得到后验，再以学习率把后验平滑到当前先验。如果一轮有多个买家，就先平均后验。

我们比较 $1/(t+1)$ 、 $1/\sqrt{t}$ 和常数 $1/2$ 。前者最稳定但很快变得保守，常数率最快但持续受噪声影响， $1/\sqrt{t}$ 位于中间。复现构造五类平均停止轮次从约 1.0 到 12.6 的买家。在随机先验、批量 100 下，最终 KL 分别约为 0.05185、0.00798、0.00702；但常数率的尾部波动约 0.00358，是保守率的 19 倍。批量降到 10 时常数率明显失稳。所以结论不是常数率绝对最好，而是更激进的学习率更快，大批量更平滑， $1/\sqrt{t}$ 给出较好的折中。这个结论依赖可识别性，而且我们的停止似然来自透明合成环境。”

收束（约 30 秒）

“RQ1 和 RQ3 分别闭合了市场链条的两端：Data-Bandit 低成本产生性能轨迹，买家的停止行为又让平台逐步学习市场先验。两组缩减实验都复现了论文的主要定性现象，同时保留了公开数据和合成设置带来的边界。”

6 老师可能追问什么

可能问题	建议回答
为什么 Bandit 终点不如 Data-All，还说它有效？	它的目标是有限搜索成本下更早找到好方案。AUC 和达到 95% oracle 的训练数刻画前期效率；预算足够时，训练全部组合的 Data-All 理应更有机会达到 oracle。
为什么不用普通 bandit？	每轮增强不同，模型奖励随输入数据变化，不满足固定随机奖励假设；Exp3 面向对抗式或非平稳序列，并保留显式探索。
重要性加权为什么除以抽样概率？	只观察被选模型的奖励。除以抽样概率可校正不同臂被观察频率不同造成的偏差；小概率事件得到更大修正。
为什么测试效用可以画成搜索曲线？	搜索和选择只使用验证分数；测试分数仅报告“验证集当前选中的方案”，不反馈给算法，因此没有直接测试泄漏。
RQ1 为什么不用运行秒数？	原始硬件、NYC 数据池和 TPOT 环境不可复刻。训练次数是透明、跨机器稳定的成本代理，但不能与原图秒数逐点比较。
Bayes 更新为什么还要学习率？	单次后验噪声大，直接替换先验会过度响应当前样本。凸组合控制每轮更新幅度，使速度和稳定性可调。
常数 $1/2$ 最终 KL 最小，为什么推荐 $1/\sqrt{t}$ ？	最后一点不是全部。常数率尾部波动大，小批量时明显失稳； $1/\sqrt{t}$ 的误差接近常数率但稳定得多。
可识别性不满足怎么办？	仅凭停止时间无法区分这些类型，应引入更多行为信号或价格实验；若始终不可区分，按论文思路合并为一个有效类型。
RQ3 与定价有什么关系？	学到的先验 μ 决定平台对不同类型收入的加权，进而影响最优价格；Theorem 5.2 还说明估计误差小时收入损失也线性受控。

可能问题	建议回答
这是原论文的完全复现吗？	不是。RQ1 使用公开 UCI 数据替代 NYC 数据池，RQ3 使用透明合成 Markov 环境。我们复现算法语义和定性结论，不声称逐点重现 Figure 3/5。

7 最终记忆卡片

RQ1

问题：组合太多，训练太贵。 **算法：**增强搜索 + Exp3，每轮只训练一个模型。 **指标：**AUC、95% oracle 训练数、最终效用。 **结果：**前期更省 27-30%，但 Data-All 终点略高；对 Data-Alt 只可称相当。

RQ3

问题：不知道真实买家比例。 **算法：**停止似然 + Bayes 后验 + 学习率平滑。 **指标：**KL、尾部均值、尾部波动。 **结果：**激进率快但抖，大批量更稳， $1/\sqrt{t}$ 折中；可识别性必不可少。

参考文献

[1] Y. Han, S. Padmanabha, S. Wang, Z. Huang, and J. Zhao. *Optimal Pricing for Data-Augmented AutoML Marketplaces*. arXiv preprint, 2023.

[2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis. Wine Quality [Dataset]. UCI Machine Learning Repository, DOI: 10.24432/C56S3T.