

数据增强 AutoML 市场：RQ1

增强-模型发现的论文实验及缩减复现

课程大作业 C.3 · RQ1/RQ3 实验复现部分

数据要素市场课程 · 中期答辩

参考论文: *Optimal Pricing for Data-Augmented AutoML Marketplaces*

2026 年 7 月 18 日

研究问题

在有限训练预算下，Data-Bandit 能否更早发现高质量的增强-模型组合？

研究对象

外部数据增强与机器学习模型的联合搜索。

核心比较

Data-Bandit、Data-All、Data-Alt 与 AutoML.

评价维度

- 发现曲线与最终效用
- AUC
- 95% oracle 增益训练次数

[Data-Bandit: 增强候选搜索与 Exp3 模型选择]

算法步骤

- ① 增强层提出候选 T_i ;
- ② 按 Exp3 概率抽取一个模型 M_i ;
- ③ 只训练 $M_i \leftarrow (D_{\text{in}} \bowtie T_i)$, 得到奖励 r_i ;
- ④ 用重要性加权 $r_i/p_i(M_i)$ 更新模型权重.

训练预算

与其在一个增强上花 $|\mathcal{M}|$ 次训练测透, 不如先花 1 次快速筛选, 从而把预算用于更多增强.

比较方法

- Data-Bandit: 每轮抽一个模型
- Data-All: 每个增强训练全部模型
- Data-Alt: 固定低成本模型筛增强, 周期性完整搜模型
- AutoML: 只搜模型, 不加入外部数据

选择依据


增强不断改变输入数据, 模型奖励并非固定分布; Exp3 适合这种非平稳/对抗式反馈.

RQ1: 原文实验设计

[原文 §6; Figure 3]

原论文设置

- 69K 个 NYC Open Data 数据集
- 约 30M 列、3B 行
- 1000 个分类/回归任务
- Random Forest、XGBoost、Neural Network 等
- 横轴：搜索时间；纵轴：效用



原文 Figure 3; 横轴为搜索时间，纵轴为效用。

[原文 Figure 3]

分类任务

- Data-Bandit 平均效用超过 0.85
- 次优方法平均效用略高于 0.70
- AutoML 约为 0.55

回归任务

- Data-Bandit 在固定时间点均高于基线
- 多数任务识别出的增强数少于 10
- 结论：更高的有限时间发现效率

原文结论

Data-Bandit 在相同搜索时间下更快获得高质量增强-模型组合.

[UCI Wine Quality; 训练调用次数作为成本代理]

数据与搜索空间

- 红/白葡萄酒，分类与回归各 30 个任务
- 2 个基础特征 + 9 个外部增强
- 6 个自包含模型族
- 每种方法最多 60 次模型训练
- 固定种子；每任务 60/20/20 划分


数据划分

- 训练集：排序增强候选、拟合模型
- 验证集：搜索与选择当前 incumbent
- 测试集：只报告验证选择方案的效用

复现边界

NYC 数据池、Metam 配置和完整代码未公开；
这里复现**预算语义和定性现象**，不逐点还原原图时间轴。

RQ1: 复现实验结果



搜索效率

- AUC 配对差: 分类 +0.00794, 回归 +0.00335
- 95% bootstrap 区间均不跨 0
- 达到 95% oracle 增益所需训练减少 30.3% / 27.5%

结果边界

- 60 次预算终点仍是 Data-All 略高, 差距 0.0012–0.0015
- Bandit 与 Data-Alt 的 AUC 区间跨 0, 只能说表现相当

数据落盘: results/tables/rq1_task_results.csv, rq1_paired_comparisons.csv, results/rq1_summary.json.