

数据增强 AutoML 市场中的最优定价

论文理论解读：市场机制、定价算法与学习保证

张博渊、林润铎、彭博宇

数据要素市场课程 · 中期答辩

参考论文: *Optimal Pricing for Data-Augmented AutoML Marketplaces*

2026 年 7 月 18 日



- 1 研究问题
- 2 市场机制
- 3 最优定价
- 4 学习与结论

核心问题

如何把**数据获取**与**模型定价**合并成一个可计算、可学习、可解释的市场机制？

核心转变：不卖“原始数据”，而卖“可验证的模型增益”

现有做法的错配

- 原始数据价值**依赖具体任务**，买方事前难判断是否有用；
- AutoML 按计算时间收费，买方可能为**无效搜索**承担成本；
- 不同买方对同一性能提升有不同支付意愿。

论文的定价对象

$$\Delta q = q(C \leftarrow D \bowtie A) - q(C_0 \leftarrow D)$$

数据增强与模型搜索共同产生的**工具性价值**

机制载体


平台预先公布价格曲线

$$x : q \in \mathcal{Q} \mapsto x(q) \geq 0,$$

对所有买方一视同仁，按最终购买的性能档位收费。

市场把数据发现、模型搜索与定价接成一个闭环

- 买方只需提交任务、初始训练数据和评估方式；平台在外部数据池中寻找增广特征与模型。
- 发现引擎持续输出性能轨迹，定价引擎将其转换为“性能—价格”菜单。



公开价格曲线把三类不确定性收进同一模型

符号	含义
$\mathcal{Q}$	离散化的模型性能集合；当前观测为 $q_t \in \mathcal{Q}$ ，性能允许暂时下降.
$P^t(q' q)$	时变马尔可夫转移矩阵；刻画从当前性能到下一期性能的搜索动态.
c, T	单位时间真实发现成本与最长搜索期数.
$\theta \sim \mu$	买方私有类型及其先验分布； $v^\theta(q)$ 是类型 θ 对性能 q 的价值.
$x(q)$	平台事前公布的统一价格曲线.

买方效用

$$u^\theta(q, \tau) = v^\theta(q) - x(q) - c\tau$$

一次交易是一条“观察—继续/停止—购买”路径

1. 进入前

平台公开 $x(q)$ 、成本 c 与性能演化指导 P^t .

2. 搜索中

每期看到最新 q_t ; 较差结果也会展示, 形成多档选择.

3. 自主决策

买方比较立即停止收益与继续搜索的期望收益.


4. 退出或购买

选择已见过的最佳净剩余档位; 保留不购买的外部选项.

关键机制性质

价格不依赖买方主动报告, 减少策略性误报空间; 买方仍通过**停止时点**表达自己的真实支付意愿.

买方最优响应是“相关收益版”的 Pandora's Box



与经典模型的差异

- 下一期收益不独立，而依赖当前 q_t ;
- 决策必须记住“历史最佳净剩余”;
- 有限时域 T 与逐期真实成本 c .

停止规则

若**立即停止效用**不低于**继续搜索的期望效用**，则停止；否则进入下一期。

一个三维 DP 足以给出最优停止策略

状态定义

(q_1, q_2, t) : q_1 是历史上净剩余最高的性能档位, q_2 是当前性能, t 是时间.

令

$$S_{\theta}(q, t) = v^{\theta}(q) - x(q) - ct, \quad B_{\theta}(q_1, q) = \arg \max_{r \in \{q_1, q\}} \{v^{\theta}(r) - x(r)\}.$$

则 Bellman 递推为

$$\Phi_{\theta}(q_1, q_2, t) = \max \left\{ S_{\theta}(q_1, t), \sum_{q \in \mathcal{Q}} P^{t+1}(q \mid q_2) \Phi_{\theta}(B_{\theta}(q_1, q), q, t+1) \right\}.$$

命题 4.1

状态数为 $|\mathcal{Q}|^2 T$, 每个状态可常数时间更新, 因此最优策略可在 $O(|\mathcal{Q}|^2 T)$ 时间内求得.

经验轨迹上的定价问题

$$\max_{x \geq 0} \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in \mathcal{S}} x(q^*(\theta, x, s)), \quad q^* = \arg \max_{q \in s} [v^{\theta}(q) - x(q)].$$

- 外层选择价格曲线 x 最大化期望收入；内层买方按净效用选择性能档位。
- $x(q) \times \mathbb{1}\{q = q^*\}$ 同时含连续变量与离散选择，不能直接交给线性求解器。
- 论文在定理 4.2 中采用“发现成本相对价值可忽略”的假设，将问题转成样本轨迹上的菜单选择。

MILP 用四类变量把买方选择与平台收入线性化

变量	类型	经济含义
$x(q)$	连续	平台对性能档位 q 的公开价格.
$z_{\theta sq}$	0-1	类型 θ 在轨迹 s 上是否选择 q .
$a_{\theta s}$	连续	该买方在该轨迹上的最大净效用.
$y_{\theta sq}$	连续	线性化 $x(q)z_{\theta sq}$, 即实际收入贡献.

选择约束

$$\sum_{q \in s} z_{\theta sq} = 1,$$
$$0 \leq a_{\theta s} - [v^{\theta}(q) - x(q)] \leq M(1 - z_{\theta sq}).$$

收入线性化

$$y \leq x, \quad y \leq Mz,$$
$$y \geq x - M(1 - z), \quad y \geq 0.$$

定理 4.2: PAC 型保证

若买方价值上界为 b ，且发现成本相对价值可忽略，当样本数满足

$$m \geq \frac{b^2}{2\varepsilon^2} \ln \frac{2}{\delta},$$

MILP 输出的 $\hat{x}$ 以至少 $1 - 2\delta$ 的概率满足

$$g(\hat{x}, \mathcal{S}) \geq g(x^*, \mathcal{S}) - \varepsilon.$$

证明路线

- ① MILP 在样本上精确求最优菜单；
- ② 单个任务收入落在 $[0, b]$ ；
- ③ Hoeffding 不等式控制经验收入与总体收入之差。

直观含义

精度提高一倍，样本量约增至四倍；机制无需准确写出完整转移矩阵，只需采样真实性能轨迹。

未知买方先验可由“停止行为”反向学习

Bayesian 更新

观察第 t 轮买方在 $y^{(t)}$ 停止后，类型后验为

$$w^{(t)}(\theta_i) = \frac{\Pr(y^{(t)} \mid \theta_i, x^{(t)}) \mu^{(t)}(\theta_i)}{\sum_j \Pr(y^{(t)} \mid \theta_j, x^{(t)}) \mu^{(t)}(\theta_j)}, \quad \mu^{(t+1)} = (1 - \eta_t) \mu^{(t)} + \eta_t w^{(t)}.$$

可识别性

若不同类型在某些价格下产生不同停止分布，重复交互即可逐步区分类型。

定理 5.2：鲁棒性

若 $\|\mu - \mu^*\|_2 \leq \varepsilon$ 且 $\|P - P^*\|_2 \leq \varepsilon$ ，则

$$\text{CEE}(\mu, P) = O(\varepsilon),$$

即估计误差只造成线性级收入损失。

发现引擎为定价机制生成可随时停止的性能轨迹

直接搜索不可行

若增广集合为 $\mathcal{P}$ 、模型集合为 $\mathcal{M}$ ，穷举需要训练

$$O(2^{|\mathcal{P}|} |\mathcal{M}|)$$

个模型。即使用 Metam 排序增广，逐轮测试全部模型仍需 $O(|\mathcal{M}| \log |\mathcal{P}|)$ 次训练。

论文的联合发现算法

- ① 用 Metam 聚类并选择候选增广；
- ② 将每个模型视作一个 Exp3 臂；
- ③ 每轮只采样并训练**一个模型**；
- ④ 用当前性能作为奖励更新模型权重。

与定价机制的接口

算法具备 anytime 性质：每轮输出一个 q_t ，买方可随时停止；序列 $(q_1, \dots, q_T)$ 正是 DP 与 MILP 所需的性能轨迹。

论文的理论结论依赖四个关键建模边界

- ① **性能动态**: $\mathcal{Q}$ 有限离散, 且未来性能只依赖当前 q_t 与时间 t ; 转移矩阵 P^t 可公开或估计.
- ② **买方偏好**: 类型空间有限、价值有界; 不同类型需要通过停止行为具有可识别性.
- ③ **价格形式**: 平台面对所有买方公布同一条按性能收费的价格曲线, 不依赖买方主动报告.
- ④ **计算假设**: 定理 4.2 在发现成本相对价值可忽略时给出 MILP 的 PAC 保证; 一般成本下的误差影响由定理 5.2 控制.

论文聚焦的范围

核心是“买方停止决策 + 平台收入最优定价”; 上游数据供应者之间如何分配收入并不是本文的主要机制设计问题.

论文的答案：围绕模型结果设计一条可计算的价格曲线

- ① **卖什么**：不直接给原始数据定价，而给数据增强后的模型性能定价；
- ② **买方如何选择**：将搜索视为相关收益的 Pandora's Box，用 DP 求最优停止；
- ③ **平台如何定价**：用 MILP 显式编码买方最优响应，并从有限轨迹学习近优价格；
- ④ **未知信息如何处理**：由停止行为学习买方先验，估计误差只带来线性级收入损失；
- ⑤ **性能轨迹从哪里来**：Metam 搜索增广，Exp3 在每轮选择一个模型，支持 anytime 交互。

核心贡献

数据发现、模型搜索、买方停止与平台定价被统一为一个与 AutoML 接口兼容的市场机制。

Q&A

$$\begin{aligned} \max_{x, a, y, z} \quad & \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in \mathcal{S}} \sum_{q \in \mathcal{S}} y(\theta, s, q) \\ \text{s.t.} \quad & 0 \leq a_{\theta, s} - [v^{\theta}(q) - x(q)] \leq M(1 - z(\theta, s, q)), \quad \forall \theta, s, q, \\ & \sum_{q \in \mathcal{S}} z(\theta, s, q) = 1, \quad \forall \theta, s, \\ & y(\theta, s, q) \leq x(q), \quad y(\theta, s, q) \leq Mz(\theta, s, q), \quad \forall \theta, s, q, \\ & y(\theta, s, q) \geq x(q) - M(1 - z(\theta, s, q)), \quad \forall \theta, s, q, \\ & x \geq 0, \quad y \geq 0, \quad z \in \{0, 1\}. \end{aligned}$$

Big- M 的作用

当 $z = 1$ 时强制 $a = v^{\theta}(q) - x(q)$ 且 $y = x(q)$; 当 $z = 0$ 时只保留上界, 并令 $y = 0$.

附录 B：联合增广—模型发现算法

- ① 初始化增广解集 $\mathcal{T} \leftarrow \emptyset$ ，并令每个模型权重 $w(M) = 1$ ；
- ② 从候选数据集中选择增广 $T_i \subseteq \mathcal{P}$ ；
- ③ 以

$$\Pr(M) = (1 - \gamma) \frac{w(M)}{\sum_{M' \in \mathcal{M}} w(M')} + \frac{\gamma}{|\mathcal{M}|}$$

采样模型 M_i ；

- ④ 在 $D_{\text{in}} \bowtie T_i$ 上训练 M_i ，以性能指标作为重要性加权奖励并更新 $w(M_i)$ ；
- ⑤ 达到停止条件后，返回观测效用最高的增广，并在该增广上选择最佳模型。

设计目的

每轮只训练一个模型，同时保留探索概率 γ ；因此能够边搜索边汇报性能，为买方的最优停止决策提供在线轨迹。

- [1] Minbiao Han, Jonathan Light, Steven Xia, Sainyam Galhotra, Raul Castro Fernandez, and Haifeng Xu.
Optimal pricing for data-augmented automl marketplaces.
arXiv preprint arXiv:2310.17843, 2025.
Version 2, May 27, 2025.
- [2] Martin L. Weitzman.
Optimal search for the best alternative.
Econometrica, 47(3):641–654, 1979.
- [3] Sainyam Galhotra et al.
Metam: Goal-oriented data discovery.
In *Proceedings of the 2023 ACM SIGMOD International Conference on Management of Data*, 2023.

