

数据增强型 AutoML 市场的最优定价

1 背景

[原文 §1, §2]

1.1 简介

[原文 §1 Introduction]

本文属于**机制设计 (Mechanism Design)** / **数据市场 (Data Market)** 方向，具体研究面向机器学习消费者的数据增强型 AutoML 市场的定价机制。[原: §1]

许多本可从机器学习获益的组织缺乏足够的训练数据，而另一些组织却积累着大量未被充分利用的数据。数据市场若能将数据供给方与 ML 消费方的需求匹配起来，可释放巨大价值。然而现有方案存在两类痛点：(i) 它们大多直接对原始数据集定价，而非对数据经由训练模型所产生的实际效用定价；(ii) 价格的形成过程缺乏透明度。此外，现有方案均未考虑通过数据增强 (*Data Augmentation*) 来提升模型精度。[原: §1, p.1-2]

数据增强 (Data Augmentation): 将外部数据池中的特征列通过数据库 JOIN 操作拼接到买家的训练数据上，使模型在更多信息上训练，从而提升性能。

在方法取向上，作者采取务实路线：不另起炉灶，而是设计一个可作为 Google Vertex AI、Amazon SageMaker 等云上 AutoML 平台“**Drop-in 替换**”的数据增强型 AutoML 市场。与标准 AutoML 的根本区别在于：(1) 平台会用外部数据池中的特征增强买方提交的训练数据；(2) 买方主要按所获模型可衡量的质量提升付费，而非按计算或模型搜索的工时成本付费。这一重心转移降低了买方参与风险，并为外部数据的货币化开辟了新的市场化机制。[原: §1, p.2]

1.2 相关工作

[原文 §2 Related Work]

前人工作要么直接对原始数据表定价，要么假设模型建在市场全部数据之上、仅研究如何出售版本化模型。本文直接将“数据 + 模型”搜索过程建模，并把搜索结果反映到定价机制中。[原: §2, p.2]

1.3 核心概念速览

- **AutoML (Automated Machine Learning)**: 自动完成特征工程、模型选择、超参数调优的 ML 开发流程。用户提供数据，平台返回训练好的模型。
- **转移矩阵 (Transition Matrix)** $P^t(q' | q)$: 描述搜索过程中模型性能从当前状态 q 跳到下一状态 q' 的概率。刻画了“继续搜下去大概能拿到多好的结果”这一关键信息。
- **价格曲线 (Price Curve)** $x(q)$: 平台事先公布的一张表，对每个可能的性能等级 q 标注一个价格。买家在参与前就知道拿到多好的模型要付多少钱。
- **Stackelberg 博弈 (Stackelberg Game)**: 平台先公布价格 (领导者)，买家看到价格后做最优停止 (跟随者)。不是纳什均衡——因为有人先动并承诺，跟随者的反应可以被精确计算 (DP) 而非猜测。
- **MILP (Mixed Integer Linear Programming, 混合整数线性规划)**: 同时包含连续变量 (价格) 和离散变量 (买家的选择 $z \in \{0, 1\}$) 的线性优化问题，可由 Gurobi、CPLEX 等工业求解器高效求解。

2 问题与方法

[原文 §3–§6]

2.1 数据增强型 AutoML 市场架构

[原文 §3 Data-Augmented AutoML Market Architecture]

平台持有大量数据集，并同时为数据增强 (即与买方训练数据 JOIN 的额外特征) 与模型进行搜索。记 $q(C \leftarrow D)$ 为在数据 D 上训练得到的模型 C 的性能指标 (如测试集准确率)。平台在预设时刻 $t = 1, \dots, T$ (例如每 5 分钟) 向买方揭示当前模型指标 $q_t \in \mathcal{Q}$, $\mathcal{Q}$ 为有限离散指标集。[原: §3, p.2–3]

性能指标集 $\mathcal{Q} = \{q_1, \dots, q_K\}$, 将连续的性能指标离散化为有限个质量等级, 使问题可用 DP 和 MILP 求解。

马尔可夫转移矩阵 $P^t(q' | q) = \Pr(Q_{t+1} = q' | Q_t = q)$ 。由于梯度下降等优化算法的“未来表现仅依赖当前参数”性质, 作者将指标演化建模为马尔可夫链。 P^t 是时变的 (t 越大, 大幅提升的概率越小), 设为公开信息 (平台可作为“建议性指引”公开, 类比 Google 广告平台公开出价指引)。[原: §3, p.3]

买方类型与估值 $\theta \in \Theta$ 。买方总体由私有类型 θ 刻画, θ 确定估值向量 $v^\theta(\cdot) \in \mathbb{R}_+^{|\mathcal{Q}|}$, 即买方对每个质量等级愿意支付的最高金额。买方知道自身 θ , 平台仅知先验分布 μ 。

[原: §3, p.3]

价格曲线与支付 $x \in \mathbb{R}_+^Q$ ，预先公布、对所有买方相同。买方支付含两部分：

$$u^\theta(q, x, c) = v^\theta(q) - x(q) - c\tau$$

- **强制部分** $c\tau$ ：数据发现成本。 c 为真实算力成本（远低于云平台计费单价，如 Vertex AI 的 \$3.465/节点小时）， τ 为停止时刻。这部分覆盖计算资源消耗，不是平台利润。
- **自愿部分** $x(q)$ ：若买方选择购买性能为 q 的模型用于推理，则支付此价格。这是平台真正的利润来源。

[原：§3, p.3]

平台的最优定价问题：在先验 μ 、类型集 Θ 与指标动态 $\{P^t\}$ 给定下，求使市场预期收益最大的价格曲线 $\{x(q)\}_{q \in Q}$ 。[原：§3, p.3]

2.2 三大技术挑战

[原文 §3 末, p.3]

- (1) 高效求最优定价机制——本文理论贡献的核心，对应 §4；
- (2) 获取/学习先验 μ ——定价模型的输入，对应 §5；
- (3) 有效搜索模型与数据并实时揭示性能——定价模型的另一项输入，对应 §6。

其中挑战 2 和 3 是为核心定价理论提供输入管线的配套工程——没有它们，定价模型没有 μ 和轨迹 S 可用，但它们各自的解（贝叶斯更新 + Exp3）在理论上均属于现有技术的应用和适配。

2.3 挑战一：计算最优定价机制

[原文 §4 Finding the Optimal Pricing Mechanism]

2.3.1 买方最优响应作为最优停止问题

[原文 §4.1 Buyer's Best Response as Optimal Stopping]

由于买方事前已知价格曲线与搜索成本，其参与过程是一个最优停止问题，实为 Pandora's Box 问题的带依赖变体：与标准 Pandora's Box 各箱子收益分布独立不同，本文的下一时刻随机收益依赖当前状态，这一依赖由马尔可夫链 $\{P^t\}$ 刻画。[原：§4, p.3–4]

DP 状态为什么是三维？ 买家停止时不一定购买当前轮的模型，而是购买历史上所有已发现模型中净效用最大的那个。因此状态必须记录：(1) q_1 ——历史最佳质量，(2) q_2 ——当前质量，(3) t ——当前轮次。

以 $\Phi(q_1, q_2, t)$ 记状态下的最优期望未来收益，其满足 Bellman 递推：

$$\Phi(q_1, q_2, t) = \max \left\{ v^\theta(q_1) - x(q_1) - ct, \quad \mathbb{E}_{q \sim P^t(\cdot|q_2)} \Phi(B(q_1, q), q, t+1) \right\}$$

其中 $B(q_1, q) = \arg \max_{r \in \{q_1, q\}} \{v^\theta(r) - x(r)\}$ 选出历史与当前中净价值更高的质量。第一项为立即停止，第二项为继续一期的期望。[原：§4, Equ. (6), p.4]

命题 2.1 (Proposition 4.1). 买方最优策略可通过动态规划在 $O(|Q|^2T)$ 时间内计算。

[原：Prop 4.1, p.4]

Algorithm 3: 最优停止 DP [原：Alg 3, §4.1, p.13]

输入： 估值 v^θ 、价格 x 、转移矩阵 P 、时域 T 、发现成本 c 。

输出： 最优停止策略 τ^* (每个状态下停还是继续)。

步骤概要：

1. 初始化三维 DP 表 $\Phi(Q, Q, T)$;
2. 终端 $t = T$: 对所有状态, $\Phi(q_1, q_2, T) = v^\theta(q_1) - x(q_1) - cT$ (只能停);
3. 对 $t = T - 1$ 递减至 1: 比较“立即停止”和“继续期望”，取大者填入 $\Phi(q_1, q_2, t)$;
4. 根据比较结果标记 $\tau^*(q_2, t) \in \{\text{STOP}, \text{CONT}\}$ 。

复杂度： DP 表有 $|Q|^2T$ 个状态，每个状态常数时间填表，总时间 $O(|Q|^2T)$ 。

注： Proposition 4.1 提供理论保证 (“可以多项式时间计算”)，Algorithm 3 是同一 DP 逻辑的伪代码实现。二者是同一方法的不同表述层次。

2.3.2 从经验数据近似求最优价格曲线

[原文 §4.2 Approximating the Optimal Price Curve from Empirical Data]

当发现成本 $c\tau$ 相对估值和价格可忽略时，一条轨迹可压缩为可购买质量集合 s (停止时刻不再重要)。给定 m 条样本轨迹 S 和先验 μ ，平台问题是最大化：

$$\max_x \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in S} x(q^*(\theta, x, s))$$

其中 $q^*(\theta, x, s) = \arg \max_{q \in s} \{v^\theta(q) - x(q)\}$ 是买家的最优选择。这是**双层优化 (Bilevel Optimization)**——外层平台选价格，内层买家最优响应。[原：§4.2]

MILP 四类决策变量： [原：Equ. (8), p.4-5, 13-14]

- $x(q)$: 每个质量的价格 (连续变量);
- $z(\theta, s, q) \in \{0, 1\}$: 二元变量, $z = 1$ 表示类型 θ 在轨迹 s 中选择质量 q ;
- $a_{\theta, s}$: 类型 θ 在轨迹 s 中能获得的最大净效用;
- $y(\theta, s, q)$: 支付变量, 用来线性化乘积 $x(q) \cdot z(\theta, s, q)$ 。

关键约束 (Big-M 法):

$$0 \leq a_{\theta,s} - [v^\theta(q) - x(q)] \leq M(1 - z(\theta, s, q)) \quad (\text{建模最优选择}) \quad (1)$$

$$\sum_{q \in s} z(\theta, s, q) = 1 \quad (\text{必须选一个质量}) \quad (2)$$

$$y \leq x, y \leq Mz, y \geq x - M(1 - z), y \geq 0 \quad (\text{线性化乘积}) \quad (3)$$

目标函数: $\max \sum_{\theta} \mu(\theta) \sum_s \frac{1}{m} \sum_q y(\theta, s, q)$ ——所有 y 的先验加权平均。

定理 2.2 (Theorem 4.2: PAC 式近似最优定价). 设发现成本 c 相对买方估值可忽略, 估值上界为 b 。则使用 $m = \frac{b^2}{2c^2} \ln \frac{2}{\delta}$ 条样本轨迹时, 上述 MILP 求得的价格曲线以至少 $1 - 2\delta$ 的概率是真实最优曲线的加性 ϵ -近似。

[原: Thm 4.2, p.4-5]

证明骨架:

1. **Lemma B.2:** 证明 MILP (8) 精确编码了有限样本上的最优响应, 得到的是样本上的精确最优价格。[原: p.14]
2. **Lemma B.4:** 用 Hoeffding 不等式控制经验平均收入与总体期望收入的偏差; 比较“经验最优价格”和“总体最优价格”, 用 union bound 合并两边的概率 $\rightarrow$ 以 $1 - 2\delta$ 概率给出 2ϵ 近似。[原: p.15]

复现时需注意的建模边界:

- 约束 $\sum_q z = 1$ 强制每个买家在每条轨迹中必须购买——即使所有净效用为负。这与正文描述的“自愿购买”语义不一致。
- 若只设 $x(q) \geq 0$ 而无价格上界, 则统一抬高所有价格不会改变选择却会无限增加收入 (目标无界)。复现时显式加入有限价格上界。
- 将价格限制在“各质量观测估值集合”内只是有限网格基线, 不是一般多质量连续定价的精确解。

2.4 挑战二: 通过交互学习放松先验已知假设

[原文 §5 Relaxing Market's Prior Knowledge through Learning]

平台不知道买家真实类型, 但可以观察停止轮次。若已知在当前价格下各类型的停止似然, 就可以用贝叶斯公式反推类型分布。[原: §5, p.5-6]

Algorithm 1: 贝叶斯学习 [原: Alg 1, §5, p.6]

输入: 初始信念 $\mu^{(0)}$ (均匀分布)、学习率序列 η_t 、每批买家数量 B 、总学习轮数 N 。

输出: 逐轮更新的信念 $\mu^{(t)}$ 。

步骤概要:

1. **阶段一：预计算停止似然。**对每种买家类型 θ_i ，用 Algorithm 3 计算其在当前价格 $x^{(t)}$ 下的最优停止策略，然后通过大量模拟轨迹统计停止轮次的概率分布 $\Pr(y \mid \theta_i, x^{(t)})$ ——这就是似然表。
2. **阶段二：在线学习循环。**每轮：
 - (a) 一批 B 个买家参与交易，观察其停止轮次 $y_1^{(t)}, \dots, y_B^{(t)}$ ；
 - (b) 对每个观测，用贝叶斯公式计算后验：

$$w^{(t)}(\theta_i) = \frac{\Pr(y^{(t)} \mid \theta_i, x^{(t)}) \cdot \mu^{(t)}(\theta_i)}{\sum_j \Pr(y^{(t)} \mid \theta_j, x^{(t)}) \cdot \mu^{(t)}(\theta_j)}$$

- (c) 批次后验取平均，用学习率平滑更新：

$$\mu^{(t+1)} = (1 - \eta_t) \mu^{(t)} + \eta_t \bar{w}^{(t)}$$

关键前提：可识别性 (Identifiability)。不同类型必须产生可区分的停止时间分布。如果两类买家在所有价格下的停止行为几乎相同，仅凭停止时间就无法区分它们。论文指出这无损失一般性：如果两类买家对平台的学习算法不可区分，可将它们合并为一个有效类型来处理。[原：§5]

定义 2.3 (估计误差代价 CEE (Cost of Estimation Error)) .

$$\text{CEE}(\mu, P) = \text{Rev}_{\mu^*, P^*}(x^*[\mu^*, P^*]) - \text{Rev}_{\mu^*, P^*}(x^*[\mu, P])$$

即：平台用估计的 (μ, P) 设计价格，但收入在真实的 (μ^*, P^*) 下实现，与真正最优价格的收入差。

[原：Def 5.1, p.6]

定理 2.4 (Theorem 5.2: 估计误差代价的上界). 若所学 μ 满足 $\|\mu - \mu^*\|_2 \leq \epsilon$ 、转移矩阵满足 $\|P - P^*\|_2 \leq \epsilon$ ，则 $\text{CEE}(\mu, P) = O(\epsilon)$ 。

[原：Thm 5.2, p.6]

证明直觉：先验误差对收入的扰动是 Lipschitz 的（收入有界）；转移矩阵误差经有限时域 DP 逐层传播，误差至多按时域和价值上界线性累积；最后用三角不等式比较真实最优和估计最优价格。该定理推广了 Theorem 4.2（去掉了 c 可忽略的假设）。[原：App. C, p.15–17]

2.5 挑战三：数据增强—模型发现过程（实现）

[原文 §6 Evaluation — Implementation of the Market]

暴力搜索 $O(2^{|\mathcal{P}|} \cdot |\mathcal{M}|)$ 不可行。本文的发现引擎分两步配合：增强选择层用 Metam 框架剪枝搜索空间，模型选择层用 Exp3 Bandit 节约训练开销。[原：§6, p.7]

Algorithm 2: 增强-模型发现算法 [原: Alg 2, §6, p.7]

输入: 训练数据 D_{tr}, D_{val} 、模型列表 $\mathcal{M}$ 、增强列表 $\mathcal{P}$ 。

输出: 最优增强 $\hat{T}$ 和对应最优模型 $\hat{M}$ 。

步骤概要:

1. 初始化所有模型权重 $w(M) = 1$, 设探索率 $\gamma = 0.1$;
2. 每轮迭代:
 - (a) Metam 增强选择模块提出候选增强 $T_i \subseteq \mathcal{P}$;
 - (b) 按 Exp3 概率分布 $\Pr(M) = (1 - \gamma) \frac{w(M)}{\sum w} + \frac{\gamma}{|\mathcal{M}|}$ 抽取一个模型 M_i ;
 - (c) 只用 T_i 增强的数据训练 M_i , 得到性能指标作为奖励;
 - (d) 重要性加权更新: $w(M_i) \leftarrow w(M_i) \cdot \exp(\gamma \cdot \text{奖励} / (|\mathcal{M}| \cdot \Pr(M_i)))$;
3. 搜索结束后, 对最有希望的 $t = \log |\mathcal{P}|$ 个增强, 用最高权重模型做最终验证和交付。

为什么省训练? Data-All 对每个增强训练全部 $|\mathcal{M}|$ 个模型; Data-Bandit 每轮只训练一个模型。同样的预算下可以探索更多增强候选。

命题 2.5 (Proposition A.1: 发现算法的近似保证). 在“最强模型的最佳增强不弱于其他增强”的条件下, 算法在 $O(\log |\mathcal{P}| + |\mathcal{M}|)$ 次模型训练内得到近似最优解:

$$m(\hat{M} \leftarrow D_{in} \bowtie \hat{T}) \geq m(M^* \leftarrow D_{in} \bowtie T^*) \times \frac{1}{\alpha} (1 - e^{-\alpha\eta}) - k\epsilon$$

其中 α, η 为性能函数 m 的曲率与子模比, k, ϵ 为常数。

[原: Prop A.1, p.12]

3 主要结论

[原文 §7]

3.1 核心理论结论

- (1) **Proposition 4.1 / Algorithm 3:** 买方最优停止策略在 $O(|\mathcal{Q}|^2 T)$ 时间内可由 DP 计算。DP 状态需同时记录历史最佳质量和当前质量。
- (2) **Theorem 4.2:** 在发现成本可忽略时, 仅用 $m = \frac{b^2}{2\epsilon^2} \ln \frac{2}{\delta}$ 条样本轨迹即可由 MILP 求得最优价格曲线的加性 ϵ -近似, 概率 $\geq 1 - 2\delta$ (PAC 保证)。
- (3) **Theorem 5.2 / Algorithm 1:** 通过与买方重复交互的贝叶斯学习可逼近真先验 μ^* , 且估计误差对收入的损失有上界 $\text{CEE} = O(\epsilon)$ 。
- (4) **Proposition A.1 / Algorithm 2:** Data-Bandit 将每个模型视为 Exp3 臂, 每轮仅训练一个模型, 在 $O(\log |\mathcal{P}| + |\mathcal{M}|)$ 次训练内收敛到近似最优解。

3.2 实验全景：三个 RQ 与算法的对应关系

三个研究问题各自验证一个技术组件，合在一起覆盖论文的完整技术栈：

表 1: 三个 RQ 与算法和定价基线的对应关系

RQ	验证什么	依赖的算法/理论	比较的基线	代码入口
RQ1	Data-Bandit 能否用更少训练找到好组合	Algorithm 2 (Exp3 Bandit)	Data-All, Data-Alt, AutoML	<code>scripts/run_rq1.py</code>
RQ2	MILP 定价是否比简单方法更赚钱	Theorem 4.2 (MILP)	Independent, Shift, Jiggle, OOS-MILP	<code>scripts/run_paper_experiments.py</code>
RQ3	能否从停止时间学到真实 μ	Algorithm 1 (贝叶斯学习)	三种学习率, 两种批量	<code>scripts/run_paper_experiments.py</code>

Algorithm 3 (最优停止 DP) 本身不被任何 RQ 单独验证——它是所有实验的底层基础设施，默认买方总是按最优策略行动。

3.3 RQ1：数据增强—模型发现的效果

[原文 §6, RQ1: How effective is our market in finding high-quality augmentations and models?]

3.3.1 验证对象和对应的算法

RQ1 验证的是 **Algorithm 2 (Data-Bandit)**。之前讲过这个算法——把每个 ML 模型看作 Exp3 的一只臂，每轮只抽取一个模型训练，用重要性加权奖励更新模型权重。问题是：这种“节约训练”的策略，会不会因为样本太少而漏掉真正好的模型组合？

3.3.2 原论文实验设置

- **数据集池：** 69K NYC Open Data 数据集（约 30M 列、3B 行）
- **任务数量：** 1000 个分类和回归任务（例：预测学校标准化考试成绩，2000 条/6 特征；预测交通事故数，400 条/4 特征）
- **模型库：** Random Forest、XGBoost、Neural Network 等多种 AutoML 可选的模型
- **性能指标：** 横轴为搜索时间（秒），纵轴为效用（Utility）。分类用准确率衡量，回归用类似指标

- **发现方法：**增强选择层用 Metam 框架剪枝搜索空间 + 模型选择层用 Exp3 抽样训练

[原： §6, p.7–8]

3.3.3 四种竞争方法

1. **Data-Bandit (本文方法)：**每轮 Metam 选一个候选增强，Exp3 按权重分布抽取一个模型训练，用该模型在此增强上的性能作为奖励更新权重。搜索结束后在最优增强上验证所有模型。
2. **Data-All (完整预算参照)：**对 Metam 选出的每个增强，训练全部 $|\mathcal{M}|$ 个模型。搜索最全面，但消耗预算最快。
3. **Data-Alt (低成本对照)：**固定一个高效模型（如 Random Forest）来评估每个增强，每隔一分钟用 TPOT AutoML 在最佳增强上做一次完整的模型搜索。用于判断收益是否真的来自 Bandit 的自适应。
4. **AutoML (纯模型搜索)：**不搜索外部数据增强，只用 TPOT 在买家原始数据上搜索最佳模型。用于量化”加入外部数据”本身的价值。

[原： §6, p.7–8]

3.3.4 原论文关键结果

- 分类任务上 Data-Bandit 平均效用 > 0.85 ，次优（Data-All 或 Data-Alt）仅 > 0.7 ，AutoML 约 0.55。
- 回归任务上同样：固定任意搜索时间点，Data-Bandit 的效用都高于所有基线。
- 大多数任务识别的增强数量不超过 10 个，说明 Metam 的剪枝有效。
- 搜索时间更短 = 买家等待更短 + 搜索成本更低——对低估值买家尤其重要。

[原： Fig. 3, §6, p.8]

结论： Data-Bandit 不仅省了训练（每轮只训一个模型），而且找到了比其他方法更好的组合——因为同样的时间预算下，它可以探索更多增强候选。

3.3.5 复现中的做法和差异

原文用的 NYC 数据池、Metam 配置和完整任务集均未公开。本项目的 RQ1 用 UCI Wine Quality 做缩减复现：

- **数据：**UCI Wine Quality 红葡萄酒和白葡萄酒数据，2 个基础特征 + 9 个特征分别作为可连接的外部增强表
- **任务：**分类（质量 ≥ 6 为好酒）和回归（预测评分）各 30 个重复任务，共 60 个任务
- **模型：**6 个自包含模型族（Linear-0.01/0.1/1/10, Quadratic, RandomFeatures），用 Ridge 回归/分类统一训练
- **预算：**每方法最多 60 次模型训练。验证集用于搜索和选择，测试集仅用于报告 Incumbent 曲线
- **指标：**final_utility（预算用尽时的测试效用）、normalized_AUC（搜索全过程的平均测试效用）、calls_to_95pct_oracle_gain（达到 oracle 的 95% 增益所需训练次数）、配对 bootstrap（同任务上方法间的 AUC 差值的置信区间）

复现关键数字：

- Data-Bandit 相对 Data-All 的 AUC 差：分类 +0.00794 [0.00340, 0.01220]，回归 +0.00335 [0.00185, 0.00481]。区间不跨 0，差异显著。
- 达到 95% oracle 增益所需训练减少：分类 30.3%，回归 27.5%。
- Data-All 的 60 次预算终点效用仍最高（分类 0.74083 vs Bandit 0.73931，回归 0.54715 vs Bandit 0.54590），但差距极小。
- Data-Bandit 与 Data-Alt 的 AUC 配对区间跨 0——只能说表现相当，不能声称显著更好。

与原文 Figure 3 的定性对比：原文结论是”Data-Bandit 可以在更短时间内达到更高效用”，复现同样观察到了这一点（AUC 显著更高）。但原文还声称”终点也最优”，复现在此点上有保留——Data-All 用满预算后略优。

3.4 RQ2：定价方法的收入比较

[原文 §6, RQ2: How do different pricing schemes perform?]

3.4.1 验证对象和对应的理论

RQ2 验证的是 **Theorem 4.2 的 MILP 定价**。纸面上 MILP 可以精确求样本最优价格，但在真实市场（样本有限、轨迹随机）中，它能比简单方法多赚多少钱？

3.4.2 原论文实验设置

- **任务数据：** NYC School Data, 100 个任务
- **设置：** $|\mathcal{Q}| = 20$ 个质量等级, $|\Theta| = 20$ 种买家类型, $m = 100$ 条样本轨迹
- **IS (In-Sample)：** 所有质量在训练轨迹中均可达, 用于训练价格曲线
- **OOS (Out-of-Sample)：** 从真实性能轨迹中随机抽取, 买家的可选质量子集受限——测试价格的泛化能力
- **指标：** 归一化期望利润 = 平台收入 / 零价格下的总福利 (总福利 = 所有买家在价格全为 0 时的最大净效用之和, 代表任何定价机制的理论收入上界)

[原: §6, p.8–9]

3.4.3 五种定价方法

1. **MILP (IS)：** 在 IS 轨迹上用 MILP (8) 求解——论文的核心方法。
2. **Independent (独立定价)：** 对于每个质量 q , 将其估值 V_q 视为只依赖先验 μ 的独立随机变量, 分别求垄断价格 $x(q) = \arg \max_p p \cdot \Pr(V_q \geq p)$ 。这是 Myerson 最优拍卖理论在单物品上的应用——但本文是多质量场景, 质量之间不独立。[原: App. D.1]
3. **Shift (偏移定价)：** 以 Independent 的定价为基准, 将每个质量的价格沿估值排序统一向上或向下偏移同一个秩位。搜索所有可能的偏移量 $k \in \{-|\Theta|, \dots, |\Theta|\}$, 取收入最大的。由于 Independent 是 $k = 0$ 的特殊情况, Shift 在训练样本上永远不会比 Independent 差。[原: App. D.1]
4. **Jiggle (微调定价)：** 从最优 Shift 出发, 反复尝试两类局部改进: (a) 对选择概率高的质量提价一档; (b) 对选择概率低的质量降价一档。只接受严格改进的修改, 直到无法继续。搜索上限为 $O(|\Theta||\mathcal{Q}|)$ 步。Jiggle 在训练样本上永远不会比 Shift 差 (Shift 是其初始解)。[原: App. D.1]
5. **OOS-informed MILP：** 直接在 OOS 轨迹上训练 MILP——作为参考上界, 不代表实际可部署方法 (因为训练时已经“偷看”了测试轨迹)。

基线间的理论关系： $\text{Jiggle} \geq \text{Shift} \geq \text{Independent}$ ——后一个总是前一个的搜索起点。三者样本上的训练目标严格递增, 但在 OOS 泛化时可能因为过拟合而出现反转。

3.4.4 原论文关键结果

- IS 中 MILP 捕获约 85% 的总福利，所有基线不足 80%。Shift/Jiggle 的目标改进关系成立。
- OOS 中 MILP 仍优于其他基线，仅落后于 OOS-informed MILP（参考上界）。
- 横轴是定价方法，纵轴是归一化利润，越高越好。MILP 在两种设置下均为最高（除 OOS-informed 外）。

[原：Fig. 4, §6, p.8–9]

结论： MILP 不仅理论上最优（Thm 4.2），实际中也比简单独立定价多赚 5–10 个百分点的福利。

3.4.5 复现中的做法和差异

原文的 School Data 估值和完整代码未公开。本项目用 10 个随机合成任务做缩减复现（种子固定 20260716）：

- $|\mathcal{Q}| = 4$ 个质量状态， $|\Theta| = 6$ 种买家类型， $T = 6$ 轮搜索
- IS 训练集：100 条轨迹（所有质量可达）。OOS 测试集：4000 条从 Markov 过程随机生成的轨迹
- 比较方法：MILP (IS)、Independent、Shift、Jiggle、OOS-informed MILP
- **特殊处理——两种支付指标：** (a) `forced_*`：严格按论文式强制选择（ $\sum_q z = 1$ ，即使净效用为负也必须买）；(b) `realized_*`：加入零价值、零价格的不购买选项后的真实可实现收入

复现关键数字：

表 2: RQ2 复现：归一化收入（均值 $\pm$ 标准误）

方法	强制 IS	强制 OOS	实现 IS	实现 OOS
MILP (IS)	0.7926 ± 0.0098	0.8678 ± 0.0094	0.4263 ± 0.0164	0.4075 ± 0.0138
Independent	0.4880 ± 0.0130	0.5654 ± 0.0131	0.4880 ± 0.0130	0.5468 ± 0.0119
Shift	0.6157 ± 0.0183	0.7205 ± 0.0153	0.4007 ± 0.0221	0.3789 ± 0.0221
Jiggle	0.6353 ± 0.0214	0.7389 ± 0.0176	0.4171 ± 0.0181	0.3982 ± 0.0166
OOS-informed MILP	0.7898 ± 0.0101	0.8726 ± 0.0090	0.4279 ± 0.0190	0.4151 ± 0.0159

与原文的定性和差异：

- 强制购买指标下，MILP 的 IS 归一化收入为 0.7926，定性接近原文的约 85%。Shift $\geq$ Independent、Jiggle $\geq$ Shift 的关系成立。

- 加入不购买选项后，本缩减设置中 Independent 的 OOS 实现收入最高 (0.5468)，而 MILP 只有 0.4075。这说明”优化强制支付”的目标函数不等于”优化真实可收收入”——评价指标的选择会改变方法排序。
- 这不是 Independent 普遍最优的结论，而是说明论文 MILP 在模型设计中假设了 $\sum_q z = 1$ 的强制购买约束，这个约束与正文描述的”自愿购买”语义之间存在 gap。

3.5 RQ3: 从停止时间学习买家类型分布

[原文 §6, RQ3: How to learn the prior distribution μ ?]

3.5.1 验证对象和对应的算法

RQ3 验证的是 **Algorithm 1 (贝叶斯平滑学习)**。理论上前提：可识别性（不同类型必须有不同的停止分布）。问题是在实际中，学习速度和稳定性如何？学习率怎么选？

3.5.2 原论文实验设置

- $|Q| = 10$ 个质量等级（如 100%, 99%, ..., 91%）， $n = 5$ 种买家类型， $T = 15$ 轮搜索上限
- **先验分布族**：随机生成的、均匀的、略微偏斜的、高度偏斜的、极端偏斜的 ($\alpha = 1, \beta = 5$ 的 Beta 分布)
- **学习率比较**： $\eta_t = 1/(t+1)$ （保守）、 $\eta_t = 1/\sqrt{t}$ （中等）、 $\eta_t = 1/2$ （激进常数）
- **批量大小**： $b = 10$ 和 $b = 100$ 。大批量 = 每轮用更多买家的停止时间先取后验平均再平滑，降低单轮噪声
- **评价指标**： KL 散度 $D_{KL}(\mu^* \parallel \mu^{(t)})$ 。横轴为学习轮数，纵轴为 KL（对数尺度）。越小越好。

[原： §6, p.9, App. D.2]

3.5.3 原论文关键结果

- 学习确实收敛到真实分布，KL 散度降至 < 0.025 。
- 更激进的学习率收敛更快，但在小批量时波动明显——常数 $1/2$ 不会随时间衰减，尾部持续受抽样噪声影响。
- 增大批量 ($b = 100$) 可平滑激进学习率的振荡。

- 该结论在五种不同先验分布上均成立。

[原: Fig. 5, App. D.2, Fig. 6–8]

3.5.4 复现中的做法和差异

RQ3 的似然来自透明合成 Markov 环境，不是原文的随机实例。但验证的是完全相同的现象：

- 显式构造 5 种可区分的停止分布：平均停止轮次分别约为 1.0、4.0、7.2、10.2、12.6，最小成对 L_1 距离约 0.656——确保可识别性假设被显式满足
- 5 种先验 $\times$ 3 种学习率 $\times$ 2 种批量 $\times$ 5 个随机种子 $\times$ 1000 轮学习 = 完整覆盖
- 指标：final_kl（最后一轮误差）、tail_mean_kl（最后 100 轮平均，避免偶然值）、tail_std_kl（最后 100 轮波动）

复现关键数字（随机先验、批量 100）：

表 3: RQ3 复现：不同学习率的收敛对比

学习率	第 1000 轮 KL	尾部平均 KL	尾部标准差
$1/(t+1)$	0.12083 ± 0.00371	0.12108	0.00015
$1/\sqrt{t}$	0.01926 ± 0.00139	0.02008	0.00062
$1/2$	0.00495 ± 0.00169	0.00607	0.00387

与原文的定性对比：

- 原文观察到”激进学习率收敛更快但更不稳定，可被大批量平滑”——复现完全验证。
- 常数 $1/2$ 的尾部标准差为 0.00387，约是 $1/(t+1)$ 的 26 倍——虽然第 1000 轮的点估计最好 (0.00495)，但过程不稳定。批量 10 时尤其严重（平均最终 KL 约 0.1732，尾部标准差约 0.0459）。
- $1/\sqrt{t}$ 在速度、稳定性和最终误差之间取得了最好的平衡，与论文正文和附录 D.2 的定性结论一致。

3.6 复现中的建模边界

- **强制购买约束 $\sum_q z = 1$ 与自愿购买语义的矛盾：**论文正文将购买描述为自愿行为，但 MILP 强制每个类型在每条轨迹购买一个模型。如果所有模型净效用为负，真实买家会退出，但 MILP 目标仍记录正支付。复现同时报告两种指标以明确这个边界。

- **价格上界的必要性**：强制购买且仅有 $x(q) \geq 0$ 时，统一抬高所有价格会无限增加收入——问题无界。复现显式加入有限价格上界。
- **估值网格不是连续定价的精确解**：将价格限制在各质量观测估值集合上是透明有限网格基线，但跨质量无差异超平面可能产生非观测估值处的最优价格。
- **开源 HiGHS 求解边界**：对 $|\mathcal{Q}| = 20, |\Theta| = 20, m = 100$ 的模型，60 秒内最优性间隙很大（约 57.6%/568%），因此不宣称完成论文规模的最优 MILP 求解。

3.7 局限性与扩展

[原文 §7 Conclusion]

作者指出本文是迈向“端到端在线 AutoML 市场”这一更大愿景的一步，承认构建完全可用的在线市场仍需解决不少重要挑战（如发现引擎的实时性、买方估值分布的真实获取等）。[原：§7, p.9]

复现项目有三项主要限制：RQ1 使用公开 UCI 数据替代原文 NYC 数据池；RQ2 的 School 数据估值和代码未公开；RQ3 的似然由透明合成 Markov 环境生成，验证的是算法语义和定性现象而非逐点复刻原文 Figure 3–5。