

# 机器学习数据获取与数据定价

《Optimal Pricing for Data-Augmented AutoML Marketplaces》讲解与实验复现

课程大作业 C.3

2026 年 7 月 16 日 版本 0.4.0

## 摘要

本文解释并缩减复现 Han 等人提出的数据增强型 AutoML 市场。平台连续搜索外部数据增强与机器学习模型，性能过程由马尔可夫链描述；买家面对公开的性能-价格曲线，求解最优停止问题；平台从样本轨迹计算收入最大化价格，并从停止轮次学习未知买家先验。本文实现 Proposition 4.1/Algorithm 3 的停止动态规划、Theorem 4.2 对应的 MILP、Algorithm 1 的平滑贝叶斯学习和 Algorithm 2 风格的 Data-Bandit。

RQ1 在 UCI Wine Quality 上构造 60 个公开可复现任务。Data-Bandit 相比 Data-All 的归一化发现曲线 AUC 在分类和回归上分别提高 0.00794 与 0.00335，配对 bootstrap 区间均不跨 0；达到 95% oracle 增益所需训练数减少 30.3% 与 27.5%，但完整预算终点仍由 Data-All 最优。RQ2 在 10 个合成任务上复现 MILP、Independent、Shift、Jiggle 的 IS/OOS 比较：论文强制购买指标下 IS MILP 捕获  $0.7926 \pm 0.0098$  的归一化福利；加入自愿购买后，指标排序发生变化。RQ3 覆盖 5 种真实先验、3 种学习率、2 种批量和 5 个随机种子，复现“大批量更平滑、常数学习率更易振荡、 $1/\sqrt{t}$  兼顾速度与稳定性”的定性结论。

复现还揭示两个建模边界：论文 MILP 强制每个买家购买，且若不显式限制价格上界会无界；有限估值网格也不是一般多质量连续定价的精确解。本文如实记录 IR 修正和 HiGHS 求解边界，不把它们扩展为新的主要研究方向。由于原文 NYC 数据池、任务估值和完整代码未公开，本文所有结论均标注为公开数据或合成设置上的缩减复现，而非 Figure 3-5 的逐点重现。

## 目录

|                                    |          |
|------------------------------------|----------|
| <b>1 论文要解决什么问题</b>                 | <b>3</b> |
| <b>2 模型与一次交易的流程</b>                | <b>3</b> |
| <b>3 买家最优停止：Proposition 4.1</b>    | <b>3</b> |
| 3.1 为什么状态是三维的 . . . . .            | 3        |
| <b>4 样本轨迹定价：MILP 与 Theorem 4.2</b> | <b>4</b> |
| 4.1 从动态过程到可购买集合 . . . . .          | 4        |
| 4.2 MILP 四类变量 . . . . .            | 4        |
| 4.3 复现时发现的边界 . . . . .             | 4        |

|                                     |   |
|-------------------------------------|---|
| 目录                                  | 2 |
| 5 未知先验学习: Algorithm 1 与 Theorem 5.2 | 5 |
| 6 数据增强-模型发现: Algorithm 2            | 5 |
| 7 实验设置与复现入口                         | 5 |
| 8 RQ1: 增强-模型发现                      | 6 |
| 9 RQ2: 定价方法比较                       | 6 |
| 10 RQ3: 从停止时间学习先验                   | 7 |
| 11 补充记录: IR 修正与求解器边界                | 8 |
| 12 测试、可复现性与限制                       | 9 |
| 13 结论                               | 9 |

## 1 论文要解决什么问题

传统 AutoML 主要搜索模型和超参数。本文研究的市场还拥有大量可连接的外部数据：买家带来一个小训练集，平台一边寻找有用的数据增强，一边训练模型，并持续展示当前最好性能。买家可以随时停止搜索，购买已经发现的某个模型；平台希望设计性能对应的价格，并控制发现过程的训练开销。

三个问题彼此耦合：搜索结果是随机序列，价格会改变买家的停止时刻，不同买家对同一性能的估值不同，而平台通常不知道真实买家类型。论文据此提出三个技术问题：如何求价格、如何学习买家先验、如何以较少模型训练发现好的增强-模型组合。

## 2 模型与一次交易的流程

令离散性能集合为  $\mathcal{Q} = \{q_1, \dots, q_K\}$ ，最长搜索轮数为  $T$ 。当前性能按时变马尔可夫链演化：

$$P^t(q' | q) = \Pr(Q_{t+1} = q' | Q_t = q).$$

买家私有类型为  $\theta \in \Theta$ ，估值曲线为  $v^\theta(q)$ ；平台知道或估计类型先验  $\mu(\theta)$ 。平台在搜索开始前发布价格曲线  $x(q) \geq 0$ 。若买家在第  $\tau$  轮购买质量  $q$ ，效用是

$$u^\theta(q, \tau) = v^\theta(q) - x(q) - c\tau,$$

其中  $c$  是每轮真实发现成本。平台的模型收入是  $x(q)$ ； $c\tau$  影响买家是否继续等待，但不是模型价格收入。

一次交易可概括为：公布价格；发现引擎依次产生性能；买家每轮比较停止与继续；停止后从已发现模型中选净效用最高者；平台观察支付和停止时间。全文的定价、学习和数据发现算法分别服务于这条流程的不同环节。

## 3 买家最优停止：Proposition 4.1

### 3.1 为什么状态是三维的

买家停止时可以购买历史中任一模型，不一定购买当前模型。DP 状态  $(q_1, q_2, t)$  中， $q_1$  表示历史上使  $v^\theta(q) - x(q)$  最大的质量， $q_2$  是当前质量， $t$  是当前轮次。未来转移只依赖  $q_2$ ，停止收益只依赖  $q_1$ ，因此完整历史可被这两个质量压缩。

令  $\Phi(q_1, q_2, t)$  为状态的最优期望效用，则 Bellman 递推为

$$\Phi(q_1, q_2, t) = \max \left\{ v^\theta(q_1) - x(q_1) - ct, \right. \quad (1)$$

$$\left. \mathbb{E}_{q \sim P^t(\cdot | q_2)} \Phi(B(q_1, q), q, t+1) \right\}, \quad (2)$$

其中  $B(q_1, q)$  返回二者中净价值较高的质量。第一项是立即停止，第二项是继续一期。 $t = T$  时只能停止，从终点向前递推即可。

**命题 3.1** (论文 Proposition 4.1). 给定估值、价格和转移矩阵，买家的最优停止策略可通过有限状态动态规划在论文给出的  $O(|\mathcal{Q}|^2 T)$  量级内计算。

证明的关键不是复杂技巧，而是找到了充分状态：历史只保留“当前净价值最佳质量”。代码 `market.py` 实现了值函数、继续策略、轨迹停止时刻以及按 Markov 状态分布传播的精确期望支付。

## 4 样本轨迹定价：MILP 与 Theorem 4.2

### 4.1 从动态过程到可购买集合

Theorem 4.2 假设发现成本相对估值和价格可忽略。一条性能轨迹可压缩成可购买质量集合  $s$ ，类型  $\theta$  的买家选择

$$q^*(\theta, x, s) \in \arg \max_{q \in s} \{v^\theta(q) - x(q)\}.$$

给定  $m$  条样本轨迹  $S$ ，经验收入目标是

$$\max_x \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in S} x(q^*(\theta, x, s)). \quad (3)$$

外层平台选择价格，内层买家最优响应，因此原问题是双层优化。

### 4.2 MILP 四类变量

论文引入价格  $x(q)$ 、最大净效用  $a_{\theta,s}$ 、选择变量  $z_{\theta,s,q} \in \{0, 1\}$  和支付变量  $y_{\theta,s,q} = x(q)z_{\theta,s,q}$ 。Big- $M$  约束使被选择质量满足

$$a_{\theta,s} = v^\theta(q) - x(q),$$

而所有其他质量的净效用不超过  $a_{\theta,s}$ 。乘积通过

$$\begin{aligned} y &\leq x, & y &\leq Mz, \\ y &\geq x - M(1 - z), & y &\geq 0 \end{aligned}$$

线性化。于是  $z = 0$  时  $y = 0$ ， $z = 1$  时  $y = x$ ，目标函数最大化  $y$  的先验加权平均。

**定理 4.1** (论文 Theorem 4.2). 若估值和收入由  $b$  有界，且发现成本可忽略，取

$$m = \frac{b^2}{2\epsilon^2} \ln \frac{2}{\delta}$$

条独立样本轨迹，则论文的经验最优价格以高概率给出总体最优收入的加性  $\epsilon$  近似。

证明分两步：先证明 MILP 精确编码有限样本上的最优响应；再对有界收入使用 Hoeffding 不等式，控制经验平均与总体期望的偏差，并比较经验最优解和总体最优解。其意义是平台可以直接从轨迹学习价格，不必先完整恢复 Markov 链。

### 4.3 复现时发现的边界

论文式约束  $\sum_q z_{\theta,s,q} = 1$  强制每个买家购买，即使全部净效用为负。若只给出  $x(q) \geq 0$  而没有有限上界，同时给所有质量价格增加常数不会改变选择，却会无限增加收入，因此强制购买模型会无界。我们的 HiGHS 后端显式加入有限价格上界；IR 版本加入零价值、零价格的不购买选项。

原有“估值诱导网格”也只能称为有限网格基线。在多质量情况下，跨质量效用无差异平面可能产生不等于任何单项观测估值的最优价格。当前小实例上，强制选择网格/MILP 收入分别为 0.48809/0.49971，IR 网格/MILP 分别为 0.36614/0.38399。这一差异用于纠正实现说明，不作为新的优化主线。

## 5 未知先验学习：Algorithm 1 与 Theorem 5.2

平台不知道真实类型，但可以观察停止轮次  $y^{(t)}$ 。若已知在当前价格下各类型的停止似然，Bayes 后验为

$$w^{(t)}(\theta_i) = \frac{\Pr(y^{(t)} \mid \theta_i, x^{(t)})\mu^{(t)}(\theta_i)}{\sum_j \Pr(y^{(t)} \mid \theta_j, x^{(t)})\mu^{(t)}(\theta_j)},$$

再做平滑更新

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t w^{(t)}.$$

可识别性是必要条件：不同类型必须产生可区分的停止分布，否则只观察停止时间无法恢复类型比例。

论文还定义估计误差代价 CEE：平台用估计的  $(\mu, P)$  设计价格，却在真实的  $(\mu^*, P^*)$  下获得收入。Theorem 5.2 说明，当先验和转移矩阵的二范数误差均不超过  $\epsilon$  时， $CEE = O(\epsilon)$ 。证明直觉是先验误差线性改变类型加权，转移误差经有限时域 DP 逐层传播，最后用三角不等式比较真实最优和估计最优价格。

## 6 数据增强—模型发现：Algorithm 2

枚举所有增强子集和模型需要指数级训练。Algorithm 2 将每个模型看作 Exp3 的一只臂：增强发现模块每轮提出候选增强，只抽取一个模型训练，用重要性加权奖励更新模型概率。这样避免对每个增强训练全部模型。

本文实现四种比较方法：Data-Bandit 每轮抽样一个模型；Data-All 对候选增强训练全部模型；Data-Alt 轮换模型；AutoML 不使用外部增强。原文依赖 Metam、约 69K NYC Open Data 数据池和多种 AutoML 系统，但这些任务与完整实现未公开，因此 RQ1 改用透明公开数据，保留查询预算和模型训练次数的核心语义。

## 7 实验设置与复现入口

环境由 `environment.yml` 固定，包含 Python、NumPy、Matplotlib 和 HiGHS。随机种子固定为 20260716。主要命令为：

```
conda env create -f environment.yml
conda activate automl-market
make test
make rq1
make paper-experiments
make report
```

RQ1 从项目内 UCI Wine Quality 归档读取红、白数据，构造 60 个分类/回归重复任务；验证集用于模型选择，测试集只用于报告。RQ2 使用 10 个随机合成任务， $|\mathcal{Q}| = 4, |\Theta| = 6$ ，100 条 IS 训练轨迹和 4000 条 Markov OOS 测试轨迹。RQ3 使用 5 个买家类型、10 个质量、15 轮搜索、1000 轮学习、批量 10/100 和 5 个随机种子。

## 8 RQ1: 增强-模型发现




图 1: 公开 UCI 任务上的发现曲线。阴影表示重复任务不确定性；横轴是实际模型训练次数。

表 1: RQ1 关键结果。AUC 差为 Data-Bandit 减 Data-All。

| 任务 | Bandit 最终效用 | All 最终效用 | AUC 差与 95% CI              | 95% 增益训练节省 |
|----|-------------|----------|----------------------------|------------|
| 分类 | 0.73931     | 0.74083  | 0.00794 [0.00340, 0.01220] | 30.3%      |
| 回归 | 0.54590     | 0.54715  | 0.00335 [0.00185, 0.00481] | 27.5%      |

Data-Bandit 在早期和中期预算下更快找到高质量组合，因此发现曲线面积优于 Data-All；但当 Data-All 用满 60 次训练，它仍取得最佳终点。Data-Bandit 与 Data-Alt 的 AUC 差在分类和回归上的区间都跨 0，故只能报告二者可比，不能声称 Bandit 显著更好。该结果复现的是论文“少训练、较快找到好组合”的定性结论，不是 Figure 3 的逐点复刻。

## 9 RQ2: 定价方法比较

论文 Appendix D.1 的 Independent 对每个质量单独求垄断价格；Shift 在所有质量上共同移动估值秩；Jiggle 从最优 Shift 出发，对高选择概率质量提价、低选择概率质量降价，并只接受严格改进。因而在训练样本的论文目标下有 Jiggle 不劣于 Shift、Shift 不劣于 Independent。




图 2: RQ2 缩减复现: 论文强制购买指标与加入外部选项后的实现收入。误差条为 10 个随机任务的标准误。

表 2: RQ2 归一化收入, 均值  $\pm$  标准误。

| 方法                | 强制 IS               | 强制 OOS              | 实现 IS               | 实现 OOS              |
|-------------------|---------------------|---------------------|---------------------|---------------------|
| MILP (IS)         | $0.7926 \pm 0.0098$ | $0.8678 \pm 0.0094$ | $0.4263 \pm 0.0164$ | $0.4075 \pm 0.0138$ |
| Independent       | $0.4880 \pm 0.0130$ | $0.5654 \pm 0.0131$ | $0.4880 \pm 0.0130$ | $0.5468 \pm 0.0119$ |
| Shift             | $0.6157 \pm 0.0183$ | $0.7205 \pm 0.0153$ | $0.4007 \pm 0.0221$ | $0.3789 \pm 0.0221$ |
| Jiggle            | $0.6353 \pm 0.0214$ | $0.7389 \pm 0.0176$ | $0.4171 \pm 0.0181$ | $0.3982 \pm 0.0166$ |
| OOS-informed MILP | $0.7898 \pm 0.0101$ | $0.8726 \pm 0.0090$ | $0.4279 \pm 0.0190$ | $0.4151 \pm 0.0159$ |

强制购买指标下, MILP 的 IS 归一化收入约为 79.3%, 定性接近原文 Figure 4 中约 85% 的福利捕获; Shift/Jiggle 的训练目标改进关系也得到复现。加入不购买选项后, Independent 在本缩减设置中取得最高实现收入。这不是 Independent 的普遍最优性结论, 而是说明强制支付目标和自愿购买收入并不等价。

## 10 RQ3: 从停止时间学习先验

实验显式构造五种可区分停止分布, 其平均停止轮次约为 1.0、4.0、7.2、10.2、12.6, 最小成对  $L_1$  距离约 0.656。比较学习率  $1/(t+1)$ 、 $1/\sqrt{t}$  和常数  $1/2$ 。




图 3: RQ3 缩减复现：随机先验、批量 100 的平均 KL 曲线，以及不同先验、学习率和批量的最终 KL。

表 3: 随机先验、批量 100、1000 轮后的 KL 散度。

| 学习率          | 最终 KL (均值 $\pm$ 标准误)  | 尾部标准差   |
|--------------|-----------------------|---------|
| $1/(t+1)$    | $0.03752 \pm 0.01698$ | 0.00008 |
| $1/\sqrt{t}$ | $0.00684 \pm 0.00444$ | 0.00019 |
| $1/2$        | $0.00519 \pm 0.00166$ | 0.00353 |

更激进学习率收敛较快，但常数  $1/2$  不会随时间减小，因此尾部持续受抽样噪声影响。批量 10 时，常数  $1/2$  在五种先验上的平均最终 KL 约 0.1965，尾部标准差约 0.0488；批量 100 明显更稳定。 $1/\sqrt{t}$  在多数设置中给出更好的速度-稳定性折中，与论文 RQ3 和 Appendix D.2 的定性结论一致。

## 11 补充记录：IR 修正与求解器边界

为了验证强制购买语义的影响，我们保留原有合成实验。论文式网格价格的训练目标为 0.4881，但加入自愿购买后 IS 测试收入仅 0.2749；IR-aware 价格的 IS 收入为 0.3746，提高 36.3%。不利先验偏移下，普通 IR 为 0.2436，鲁棒 IR 为 0.2805，提高 15.1%。这些数字用于说明外部选项的重要性，而不是替代论文 RQ2。




图 4: 原有机制边界实验：强制购买目标、IR 和鲁棒 IR 的实现收入。

对  $|\mathcal{Q}| = 20, |\Theta| = 20, m = 100$  的探索性 HiGHS 模型，重复轨迹压缩后仍有 4220/4580 个变量和 9960/10320 个约束。60 秒运行的强制/IR 模型最优性间隙分别约 57.6%/568%。因此本文不宣称完成论文规模的最优 MILP，只把它记录为开源求解器和当前建模的透明边界，并按课程重点停止进一步性能调优。

## 12 测试、可复现性与限制

当前 14 个测试覆盖：Markov 采样确定性；停止 DP；外部选项和精确期望支付；强制与 IR 收入差异；单质量垄断价格；小实例 MILP 目标审计；重复可达集合压缩；Shift/Jiggle 训练目标关系；三种学习率；RQ1 的预算、oracle 和 bootstrap 统计。未安装可选的 `highspy` 时只跳过三个 MILP 测试，基础路径仍可运行。

本文有三项主要限制。第一，原文 RQ1 的 NYC 数据池、Metam 配置和完整实现未公开，公开数据复现只能验证定性行为。第二，原文 RQ2 的 School 数据估值和代码未提供，本文不能逐点还原 Figure 4。第三，RQ3 的似然由透明的合成 Markov 环境生成，验证的是学习率、批量和可识别性现象，而不是复刻作者的每一个随机实例。

所有原始 CSV/JSON、图、环境文件和构建命令均保存在工程中。详细的中文阅读路线见 `docs/paper_walkthrough.md`。

## 13 结论

本项目已经形成从论文理解到实验复现的完整链条：用 DP 描述买家停止，用样本平均 MILP 描述平台定价，用停止似然学习市场先验，用 Data-Bandit 控制增强-模型搜索预算。RQ1/RQ2/RQ3 的缩减实验均复现了论文的主要定性现象，同时对不可获得数据和代码造成的边界作了明确说明。

最重要的复现认识有三点：买家状态必须同时记录历史最佳净价值和当前 Markov 状态；论文 MILP 的统计保证建立在有限有界收入和强制选择目标上；停止时间能够学习类型先验的前提是行为可识别。已有 IR、鲁棒性和连续 MILP 结果被保留为辅助分析，后续课程工作优先围绕讲解、复现实验核验和展示组织，而不再扩展大规模优化探索。

## 参考文献

- [1] Y. Han, S. Padmanabha, S. Wang, Z. Huang, and J. Zhao. Optimal Pricing for Data-Augmented AutoML Marketplaces. arXiv preprint, 2023 (local manuscript revision used in this project).
- [2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis. Wine Quality [Dataset]. UCI Machine Learning Repository, DOI: 10.24432/C56S3T.