

机器学习数据获取与数据定价

《Optimal Pricing for Data-Augmented AutoML Marketplaces》复现与改进阶段报告

课程大作业 C.3

2026 年 7 月 16 日 版本 0.3.0

摘要

本文复现 Han 等人提出的数据增强型 AutoML 市场的核心机制：平台将买家数据与外部数据连接，联合搜索增强数据和模型，并按模型性能定价。理论部分实现了买家的马尔可夫最优停止动态规划、样本轨迹上的价格曲线优化、基于停止时间的买家先验学习，以及 Algorithm 2 的增强-模型老虎机发现过程。公开数据 RQ1 缩减复现基于 UCI Wine Quality 的红、白葡萄酒数据构造 60 个重复任务；在 60 次模型训练预算下，Data-Bandit 的最终效用与穷举 Data-All 相差仅 0.0012-0.0015，但达到 95% oracle 增益所需训练数减少 27.5%-30.3%，且归一化发现曲线面积的配对优势在分类和回归上均不跨越 0。我们进一步指出，论文的经验定价程序式 (7)/(8) 与正文的“自愿购买”叙述存在不一致：程序强制每个买家从已发现模型中选择一个，即使所有模型的净效用均为负。加入不购买外部选项后，IR 定价把同分布测试收入从 0.275 提高到 0.375；不利先验偏移下，鲁棒 IR 收入为 0.280，相比普通 IR 提高 15.1%。先验学习实验的 KL 散度由 0.0311 降至 0.0069。本文明确区分公开数据上的定性复现与原文不可获得的 69K NYC 数据池 Figure 3 逐点重现。

目录

1 问题描述与研究动机	3
2 论文整体思路与建模	3
2.1 市场参与者与性能过程	3
2.2 买家最优停止动态规划	3
2.3 样本轨迹上的价格曲线	4
2.4 未知先验的贝叶斯学习	4
2.5 数据增强-模型发现	5
3 实现设计与可复现性	5
4 机制问题与改进方案	5
4.1 问题：定价程序缺少“不购买”选项	5
4.2 改进一：个体理性 (IR) 外部选项	6
4.3 改进二：先验偏移下的鲁棒 IR 定价	6

目录	2
5 实验结果与分析	6
5.1 RQ1: 公开数据上的增强-模型发现	6
5.2 定价结果	8
5.3 先验学习结果	8
5.4 运行结果与测试证据	9
6 局限性、后续计划与中期展示安排	9
7 结论	10

1 问题描述与研究动机

标准 AutoML 平台主要搜索模型和超参数，并按计算时间收费。论文 [1] 考虑另一类市场：买家只有少量训练数据，平台拥有可连接的外部数据池。平台一边寻找有用的增强特征，一边搜索模型，并持续向买家展示当前最优性能。买家可以决定继续搜索还是停止，并可购买已发现模型。

该问题把两个通常分开的主题连接起来：其一是**数据获取**，即从大量外部表中寻找与当前任务有关的增强；其二是**数据定价**，即不直接出售原始表，而是按照增强最终带来的模型性能定价。核心困难在于：性能搜索是随机、序贯且有成本的，买家的性能估值又是私有信息，平台必须同时预判买家的停止行为与购买行为。

本文阶段工作的目标如下：

- (1) 理解并实现论文的马尔可夫最优停止、经验价格曲线和先验学习；
- (2) 在公开表格数据上缩减复现 RQ1 的 augmentation-model discovery；
- (3) 复现论文 RQ2/RQ3 所研究的定价与学习现象；
- (4) 找出机制中的可操作问题，给出理论修正并通过实验比较；
- (5) 建立可重复运行、可测试、可生成 PDF、可版本化管理的项目工程。

2 论文整体思路与建模

2.1 市场参与者与性能过程

令离散性能集合为 $\mathcal{Q} = \{q_1, \dots, q_K\}$ ，搜索时刻为 $t = 1, \dots, T$ 。当前性能按照时变马尔可夫链演化：

$$P^t(q' | q) = \Pr(Q_{t+1} = q' | Q_t = q).$$

买家私有类型为 $\theta \in \Theta$ ，类型决定估值曲线 $v^\theta(q)$ ；平台仅知道类型先验 $\mu(\theta)$ 。平台事先发布统一价格曲线 $x : \mathcal{Q} \rightarrow \mathbb{R}_+$ 。若买家在时刻 τ 停止并购买性能 q 的模型，效用为

$$u^\theta(q, \tau) = v^\theta(q) - x(q) - c\tau,$$

其中 c 是每轮真实发现成本。平台的主要收入是模型支付 $x(q)$ ，发现成本 $c\tau$ 用于覆盖搜索成本。

2.2 买家最优停止动态规划

状态 (q_1, q_2, t) 分别记录当前净价值最高的历史性能、当前性能和时刻。令 $\Phi(q_1, q_2, t)$ 为从该状态出发的最优期望效用，则论文的递推为

$$\Phi(q_1, q_2, t) = \max \left\{ v^\theta(q_1) - x(q_1) - ct, \right. \quad (1)$$

$$\left. \mathbb{E}_{q \sim P^t(\cdot | q_2)} \Phi \left(\arg \max_{r \in \{q_1, q\}} [v^\theta(r) - x(r)], q, t + 1 \right) \right\}. \quad (2)$$

命题 2.1 (论文 Proposition 4.1). 给定价格曲线、类型估值与转移矩阵，买家的最优停止策略可在 $O(|\mathcal{Q}|^2 T)$ 时间内由动态规划计算。

证明 insight. 未来性能仅依赖当前性能 q_2 ，历史只需保留“目前净价值最高的性能” q_1 ，因此状态空间是 $|Q|^2T$ 。从 T 时刻的强制停止边界条件向前递推，每个状态比较立即停止与继续一期的期望效用。若转移期望通过矩阵运算实现，总复杂度为论文给出的多项式量级；我们的实现保留了显式状态循环，便于逐项核对。

2.3 样本轨迹上的价格曲线

当发现成本相对估值可忽略时，论文把一条性能轨迹 $s = [q_1, \dots, q_T]$ 看成可购买质量集合，并定义

$$q^*(\theta, x, s) \in \arg \max_{q \in s} \{v^\theta(q) - x(q)\}.$$

经验收入目标为

$$\max_x \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in S} x(q^*(\theta, x, s)). \quad (3)$$

论文使用二元变量 $z(\theta, s, q)$ 表示选择，连续变量 $y = x(q)z$ 表示支付，并用 Big- M 约束将双层问题线性化为 MILP。

定理 2.2 (论文 Theorem 4.2). 若发现成本可忽略、估值上界为 b ，取

$$m = \frac{b^2}{2\epsilon^2} \ln \frac{2}{\delta}$$

条独立样本轨迹，则 MILP 得到的价格曲线以至少 $1 - 2\delta$ 的概率是总体最优价格曲线的加性 ϵ 近似。

证明 insight. 第一步证明 MILP 精确表示有限样本上的最优响应和支付；第二步对固定价格曲线使用 Hoeffding 不等式控制经验收入与总体收入的偏差，再比较经验最优解与总体最优解。关键意义是：定价不要求显式恢复完整马尔可夫链，只需采样发现轨迹即可获得 PAC 风格保证。

2.4 未知先验的贝叶斯学习

论文根据观测到的停止轮次 $y^{(t)}$ 更新类型信念：

$$w^{(t)}(\theta_i) = \frac{\Pr(y^{(t)} | \theta_i, x^{(t)}) \mu^{(t)}(\theta_i)}{\sum_j \Pr(y^{(t)} | \theta_j, x^{(t)}) \mu^{(t)}(\theta_j)}, \quad \mu^{(t+1)} = (1 - \eta_t) \mu^{(t)} + \eta_t w^{(t)}.$$

在可识别性成立时，反复交互使估计先验趋近真实先验。论文进一步定义估计误差代价 CEE，即使用估计的 (μ, P) 定价而在真实 (μ^*, P^*) 下损失的收入。

定理 2.3 (论文 Theorem 5.2). 若 $\|\mu - \mu^*\|_2 \leq \epsilon$ 且 $\|P - P^*\|_2 \leq \epsilon$ ，则估计错误导致的收入损失满足 $\text{CEE}(\mu, P) = O(\epsilon)$ 。

证明思路是分别控制先验误差对收入加权的影响，以及转移矩阵扰动经动态规划递推产生的效用误差，再通过三角不等式合并。

2.5 数据增强-模型发现

暴力枚举增强集合和模型需要 $O(2^{|P|}|\mathcal{M}|)$ 次训练。论文 Algorithm 2 在 Metam 数据发现框架上加入 Exp3 对抗多臂老虎机：每个模型视为一只臂，每轮只训练一个模型；增强候选通过相似性聚类及 Thompson/贪心策略选择。本文保留其关键预算语义，实现 Data-Bandit、Data-All、Data-Alt 与不使用外部数据的 AutoML 四种方法。由于论文的 69K NYC 数据集池、Metam 配置和完整市场实现未公开，本文采用公开数据构造透明的小规模连接任务，并把结论限定为算法行为和样本效率的定性复现，而非 Figure 3 的逐点重现。

3 实现设计与可复现性

代码分为五个核心模块：

- `market.py`: 马尔可夫轨迹采样、三维停止 DP、策略执行；
- `pricing.py`: 式 (3)、IR 收入、价格候选网格与 independent baseline；
- `learning.py`: 停止时间似然下的平滑贝叶斯更新；
- `discovery.py`: 公开表格数据加载、模型族评分表及四种 RQ1 发现策略；
- `experiments.py`: 固定种子数据生成、训练/测试/OOS 评估和作图。

实验使用 $|Q| = 4$ 、 $|\Theta| = 6$ 、 $T = 6$ 、240 条训练轨迹和 4000 条测试轨迹。价格候选取每个质量上的 0 与所有类型估值，共精确枚举 $7^4 = 2401$ 条曲线。随机种子为 20260716。以下命令会依次运行测试、实验并编译本报告：

```
make all
```

原始数值同时保存为 `results/summary.json`、`results/rq1_summary.json` 及 `results/tables/` 下的逐任务 CSV，避免只能从图中读取结果。RQ1 使用 30 个分类和 30 个回归重复任务；每个任务的验证集只用于选择模型，测试集只用于报告当前验证集 incumbent，配对 bootstrap 使用固定种子和 10000 次重采样。

4 机制问题与改进方案

4.1 问题：定价程序缺少“不购买”选项

正文称模型价格 $x(q)$ 是买家自愿支付，但式 (3) 以及 MILP 约束 $\sum_{q \in s} z(\theta, s, q) = 1$ 强制每个类型在每条轨迹上选择一个模型。若

$$\max_{q \in s} \{v^\theta(q) - x(q)\} < 0,$$

真实理性买家应不购买，而原程序仍选择“亏损最少”的模型并把 $x(q)$ 记为平台收入。因此，经验目标可能偏好不可实施的高价。

4.2 改进一：个体理性 (IR) 外部选项

加入虚拟选项 $\perp$, 令 $v^\theta(\perp) = x(\perp) = 0$, 将选择集合改为 $s \cup \{\perp\}$:

$$q_{\text{IR}}^* \in \arg \max_{q \in s \cup \{\perp\}} \{v^\theta(q) - x(q)\}. \quad (4)$$

在 MILP 中只需增加 $z(\theta, s, \perp)$, 保留选择和为 1, 并固定其价格、估值和支付为 0; 或者增加约束使购买选项的效用非负。

命题 4.1 (IR 修正的性质). 式 (4) 对每个类型和轨迹均满足事后个体理性。对任意固定价格曲线, 允许退出后的可实现收入不高于强制选择目标; 两者相等当且仅当强制目标选择的模型在所有正概率类型-轨迹对上均具有非负净效用 (忽略零效用处的平局规则)。

证明。 外部选项效用为 0, 因此最优选择的效用至少为 0, 得到个体理性。强制选择与 IR 选择的差异只发生在所有模型效用均小于 0 的事件上; 强制目标在该事件中记录正价格, IR 目标记录 0, 故前者逐样本不小于后者。没有此类正概率事件时两目标一致, 反之严格产生虚假支付。□

4.3 改进二：先验偏移下的鲁棒 IR 定价

真实市场的类型先验会变化。设 $\mathcal{U}$ 是由当前估计先验、均匀先验、低支付意愿偏移和高支付意愿偏移组成的候选集合, 我们求解

$$\max_{x \geq 0} \min_{\mu \in \mathcal{U}} \mathbb{E}_{\theta \sim \mu, s \sim S} [x(q_{\text{IR}}^*(\theta, x, s))].$$

该 max-min 目标牺牲部分同分布平均收入, 换取先验变化时的收入下界。小规模实验仍可精确枚举; 大规模版本可在原 MILP 上增加场景收入变量 r , 并对每个 $\mu \in \mathcal{U}$ 加入 $r \leq \text{Rev}_\mu(x)$ 。

5 实验结果与分析

5.1 RQ1: 公开数据上的增强-模型发现

实验采用 UCI Wine Quality 红、白葡萄酒数据 [2]。每次划分中, 前两个理化指标构成买家的基础表, 其余九个指标分别视为可按不可变行键连接的外部表; 候选增强按训练集上的目标相关系数排序, 作为 Metam profile/likelihood 的透明小规模替代。分类任务为判断质量是否至少为 6, 回归任务直接预测质量; 每种颜色重复 15 次, 共得到每类问题 30 个配对任务。模型池包含四个不同岭惩罚的线性模型、二次特征模型和随机 ReLU 特征模型, 统一预算为 60 次训练。




图 1: 公开数据 RQ1 缩减复现。曲线为训练预算不超过横轴数值时可达到的测试效用均值及 95% 置信带；方法结束后用其最终效用向右延伸。右图统计达到“基础效用到完整验证 oracle 增益的 95%”所需训练次数，61 表示预算内未达到。

表 1: 最多 60 次训练预算下的 RQ1 结果。AUC 是预算 $1, \dots, 60$ 下验证集 incumbent 测试效用的均值，方法提前结束后沿用其最终效用；括号内为标准误。

任务	方法	最终效用	归一化 AUC	达到 95% 增益的训练数
分类	Data-Bandit	0.7393 (0.0045)	0.7381	11.93
	Data-All	0.7408 (0.0039)	0.7301	17.13
	Data-Alt	0.7360 (0.0049)	0.7342	15.97
	AutoML	0.6619 (0.0052)	0.6622	59.00
回归	Data-Bandit	0.5459 (0.0026)	0.5449	18.43
	Data-All	0.5471 (0.0025)	0.5416	25.43
	Data-Alt	0.5459 (0.0026)	0.5441	20.47
	AutoML	0.5126 (0.0018)	0.5126	61.00

Data-All 在完整预算末端取得最高效用，这是穷举所有增强-模型组合的预期结果；Data-Bandit 的最终差距仅为分类 0.00153、回归 0.00124。更重要的是，Data-Bandit 达到 95% oracle 增益的平均训练数相对 Data-All 分别减少 30.3% 和 27.5%，并在分类、回归的归一化 AUC 上分别领先 0.00794 和 0.00335。对同一数据划分做配对 bootstrap 后，95% 区间分别为 $[0.00340, 0.01220]$ 与 $[0.00185, 0.00481]$ ，Data-Bandit 分别在 24/30 和 23/30 个任务上胜过 Data-All。相对 Data-Alt 的 AUC 均值虽为正，但区间跨越 0，因此证据只支持“与 Data-Alt 相当”，不能声称稳定优于它。AutoML 不搜索外部数据，在两类任务上均明显落后。由此，本实验支持论文 RQ1 的核心样本效率结论，但不支持把数值外推到原文 NYC 市场规模。

5.2 定价结果

表 2: 价格机制收入比较。所有“实现收入”均允许买家不购买。

机制	论文式训练目标	训练实现	IS 测试	OOS 测试
Paper forced-choice	0.4881	0.2687	0.2749	0.1106
Independent	0.3361	0.3245	0.3280	0.2169
IR-aware (本文)	0.4161	0.3661	0.3746	0.2436
Robust IR (本文)	0.3426	0.3327	0.3367	0.2805




图 2: 加入不购买选项后, 各价格曲线的可实现收入。OOS 将更多概率质量移向低支付意愿类型。

论文式强制选择解的训练目标为 0.4881, 但训练实现收入只有 0.2687, 说明目标中包含大量不会发生的支付。其价格曲线为 (0.22, 0.39, 0.70, 1.02); 按类型先验计, 80% 的类型在至少一类可达集合上会因负效用而退出。IR-aware 直接优化真实购买行为, 在 IS 测试上达到 0.3746, 相比论文式价格提高 36.3%。

OOS 场景把先验更多地移向低支付意愿类型。普通 IR 收入从 0.3746 降为 0.2436, 而鲁棒 IR 采用更平缓的价格 (0.20, 0.25, 0.31, 0.50), 获得 0.2805: 相对普通 IR 提高 15.1%, 相对论文式价格提高 153.6%。代价是 IS 收入比普通 IR 低 10.1%。这符合 max-min 定价的预期权衡。

5.3 先验学习结果

为满足论文的可识别性要求, 我们设置一个零模型价格的短期探索阶段, 并保留每轮发现成本 $c = 0.03$ 。不同估值曲线因“继续等待高性能”的意愿不同而产生不同停止时间分布。每轮使用 100 个买家观测, 学习率为 $1/\sqrt{t}$ 。




图 3: 基于停止轮次的买家类型先验学习。

KL 散度从均匀初始化时的 0.0311 降至 0.0069，复现了论文 RQ3 的定性结论：只观察停止时间也能逐步恢复类型先验。但类型 4-6 的停止分布仍较接近，最终概率存在混淆；这也说明论文定理中的“可识别性”不是自动成立的，平台需要设计具有信息量的探索价格或收集额外行为信号。

5.4 运行结果与测试证据

```
$ make test
Ran 8 tests in 0.026s
OK

$ make rq1
Completed RQ1 on 60 repeated tasks.

$ make experiment
Completed 4 pricing schemes.
Results: results/summary.json
```

单元测试覆盖：马尔可夫采样可重复性、DP 的继续/停止判断、缺少外部选项产生不可实现收入、单质量情形下 IR 网络解与垄断价格的一致性、四种发现方法的预算约束、Data-All oracle 性质、相对增益训练数以及配对 bootstrap 的确定性。

6 局限性、后续计划与中期展示安排

当前阶段已完成公开数据上的 RQ1 缩减复现，但仍有三项重要边界。第一，论文的大规模 NYC 数据池和作者完整实现未公开，因此不能把本实验视为 Data-Bandit Figure 3 的逐点重现；第二，当前精确价格网格只适用于小 $|Q|$ ，最终版本应增加 Gurobi/SCIP 的 MILP 接口；第三，RQ1 已有重复划分和配对区间，但 RQ2/RQ3 定价与先验学习结果仍主要来自单个固定随机种子。

后续按以下顺序推进：

- (1) 在 $|Q| = 20, |\Theta| = 20, m = 100$ 的论文设置上运行 MILP；

- (2) 对先验偏移强度、发现成本和转移矩阵估计误差做消融实验；
- (3) 运行 20–50 个随机种子并报告均值、标准差和显著性；
- (4) 根据课堂反馈迭代已完成的 17 页中期展示与讲稿；
- (5) 将本报告扩写为最终报告，补齐完整实验环境、消融表格与附录证明。

7 结论

本文建立了一个可运行、可测试和可版本化的复现工程，实现了论文的增强–模型发现、最优停止、经验定价与先验学习核心。公开数据实验表明，Data-Bandit 能以更小训练预算接近 Data-All 的最终效用；机制分析同时发现，论文经验程序缺少“不购买”选项，会把负效用买家的强制支付误记为收入。加入外部选项后，定价目标与正文的自愿购买语义一致，并在合成实验中显著提高可实现收入；鲁棒 IR 定价则对买家先验偏移更稳定。当前证据支持这些定性结论，但最终结论仍需通过 RQ2/RQ3 多种子实验、论文规模 MILP 和转移误差消融加强。

参考文献

- [1] Y. Han, S. Padmanabha, S. Wang, Z. Huang, and J. Zhao. Optimal Pricing for Data-Augmented AutoML Marketplaces. arXiv preprint, 2023 (local manuscript revision used in this project).
- [2] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis. Wine Quality [Dataset]. UCI Machine Learning Repository, DOI: 10.24432/C56S3T.