

机器学习数据获取与数据定价

Optimal Pricing for Data-Augmented AutoML Marketplaces

复现、问题与改进

课程大作业 C.3 | 中期展示

2026 年 7 月 | 项目版本 v0.3.0

这篇论文解决什么问题？

现实矛盾


- 买家有 ML 任务，但训练数据少
- 平台拥有大量可连接的外部数据
- 原始数据价值难以事前判断、难以直接定价

论文的核心想法

- 联合搜索外部数据增强 + ML 模型
- 持续向买家展示当前模型性能
- 按可测量的模型性能/效用定价
- 买家自主决定继续搜索或停止

数据获取与数据定价不再是两个独立问题

市场工作流：从买家数据到价格曲线



平台设计的是统一价格曲线 $x: Q \rightarrow \mathbb{R}_+$ ，而不是给每个原始数据集单独标价。

性能发现过程

- 离散性能集合: $\mathcal{Q} = \{q_1, \dots, q_K\}$
- 搜索轮次: $t = 1, \dots, T$
- 马尔可夫转移:

$$P^t(q' | q) = \Pr(Q_{t+1} = q' | Q_t = q)$$

买家与支付

- 私有类型: $\theta \in \Theta$, 先验 $\mu(\theta)$
- 性能估值: $v^\theta(q)$
- 模型价格: $x(q)$; 每轮发现成本: c
- 停止于 τ 并购买 q 时:

$$u^\theta(q, \tau) = v^\theta(q) - x(q) - c\tau$$

平台问题

给定 (μ, P) , 如何设计 x , 在买家最优响应下最大化期望收入?

核心理论一：买家的最优停止 DP

状态 (q_1, q_2, t) : q_1 是历史净价值最高的性能, q_2 是当前性能。

$$\Phi(q_1, q_2, t) = \max \left\{ v^\theta(q_1) - x(q_1) - ct, \right. \\ \left. \mathbb{E}_{q \sim P^t(\cdot | q_2)} \Phi \left(\arg \max_{r \in \{q_1, q\}} [v^\theta(r) - x(r)], q, t + 1 \right) \right\}.$$

Proposition 4.1

论文给出：最优停止策略可用 DP 在 $O(|Q|^2 T)$ 时间内计算。

Insight

马尔可夫性压缩了历史：不必保存整条轨迹，只保留当前状态和历史最佳选择；从 T 向前比较“立即停止”和“继续一期”。

核心理论二：样本轨迹上的最优价格曲线

当发现成本相对估值可忽略，对轨迹 $s = [q_1, \dots, q_T]$:

$$q^*(\theta, x, s) \in \arg \max_{q \in s} \{v^\theta(q) - x(q)\}, \quad \max_x \sum_{\theta} \mu(\theta) \frac{1}{m} \sum_{s \in S} x(q^*(\theta, x, s)).$$

MILP 变量

- $x(q)$: 价格曲线
- $z(\theta, s, q) \in \{0, 1\}$: 买家选择
- $y(\theta, s, q) = x(q)z(\theta, s, q)$: 支付
- Big-M: 线性化最优响应和乘积

Theorem 4.2: PAC 保证

估值上界为 b 时，使用

$$m = \frac{b^2}{2\epsilon^2} \ln \frac{2}{\delta}$$

条轨迹，以至少 $1 - 2\delta$ 概率获得加性 ϵ 近似。

核心理论三：未知先验学习与发现算法

Algorithm 1: 从停止时间学习 μ

$$w^{(t)}(\theta_i) = \frac{\Pr(y^{(t)} \mid \theta_i, x^{(t)})\mu^{(t)}(\theta_i)}{\sum_j \Pr(y^{(t)} \mid \theta_j, x^{(t)})\mu^{(t)}(\theta_j)}$$

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t w^{(t)}.$$

Theorem 5.2: 若 μ, P 的估计误差至多 ϵ , 收入损失 CEE 为 $O(\epsilon)$ 。

Algorithm 2: 增强-模型发现

- Metam 搜索增强候选
- 相似性聚类 + Thompson/贪心抽样
- 每个 ML 模型视作一只臂
- Exp3 每轮仅训练一个模型
- 避免 $O(2^{|\mathcal{P}|}|\mathcal{M}|)$ 暴力搜索

目前已经实现什么？


已完成

- 最优停止三维 DP 与策略执行
- Markov 性能轨迹模拟
- 论文强制选择经验目标
- 2401 条候选价格曲线精确搜索
- Independent pricing 基线
- 停止时间贝叶斯先验学习
- Data-Bandit / All / Alt / AutoML
- IR-aware 与 Robust IR 改进
- 测试、图表、JSON/CSV、PDF 报告

两组实验设置

- RQ1: UCI Wine Quality 红/白数据
- 2 个基础特征 + 9 个外部表
- 分类/回归各 30 个重复任务
- 6 个模型, 预算 60 次训练
- RQ2/3: $|Q| = 4, |\Theta| = 6, T = 6$
- 240 条训练、4000 条测试轨迹
- 固定种子: 20260716

RQ1 缩减复现: Data-Bandit 更快接近 oracle




相对 Data-All

- 95% 增益训练数: 分类 -30.3%, 回归 -27.5%
- AUC 配对差: +0.00794、+0.00335
- bootstrap 95% 区间均不跨 0

边界

Data-All 的 60 次预算末端效用仍最高; Data-Bandit 只落后 0.0012-0.0015。相对 Data-Alt 的 AUC 区间跨 0, 不能声称稳定领先。

复现结果：定价与先验学习



观察

- IR-aware: IS 测试收入最高
- Robust IR: OOS 收入最高
- 先验学习 KL: 0.0311 $\rightarrow$ 0.0069
- 停止时间有信息, 但类型可识别性不是自动成立

发现的问题：正文“自愿购买”与 MILP 强制选择不一致

论文程序中的关键约束

$$\sum_{q \in s} z(\theta, s, q) = 1$$

它强制每个类型在每条轨迹中购买一个模型。

真实理性行为

如果

$$\max_{q \in s} \{v^\theta(q) - x(q)\} < 0,$$

买家应当**不购买**。

原目标的偏差

MILP 仍选择“亏损最少”的模型，并把正价格记作平台收入，因此可能偏好不可实施的高价曲线。

实验中强制目标为 0.4881，但允许退出后的训练实现收入仅 0.2687。

改进一：加入个体理性外部选项

增加虚拟选项 $\perp$ ：

$$v^\theta(\perp) = x(\perp) = 0, \quad q_{\text{IR}}^* \in \arg \max_{q \in s \cup \{\perp\}} \{v^\theta(q) - x(q)\}.$$

理论性质

- 每个类型-轨迹对都满足事后个体理性
- 可实现收入不再包含负效用买家的虚假支付
- 若原选择净效用处处非负，两目标完全一致

MILP 如何修改？

- 加入 $z(\theta, s, \perp)$
- 保留选择和为 1
- 固定外部选项价格、估值、支付为 0
- 或显式约束购买效用非负

改进二：先验偏移下的鲁棒 IR 定价

候选先验集合 $\mathcal{U}$ 包含估计先验、均匀先验、低/高支付意愿偏移：

$$\max_{x \geq 0} \min_{\mu \in \mathcal{U}} \mathbb{E}_{\theta \sim \mu, s \sim S}[x(q_{\text{IR}}^*(\theta, x, s))].$$

机制	IS 测试	OOS 测试	主要定位
Paper forced-choice	0.2749	0.1106	原论文式目标
Independent	0.3280	0.2169	边际定价基线
IR-aware	0.3746	0.2436	同分布最优
Robust IR	0.3367	0.2805	抗先验偏移

Robust IR 相比普通 IR：OOS +15.1%，代价是 IS -10.1%。

当前结论应该如何解读？


已有证据支持

- 论文核心停止与定价机制可实现
- 公开数据支持 Data-Bandit 的样本效率
- 缺少外部选项会系统性高估收入
- IR 修正提高可实现收入
- max-min 定价提高分布偏移稳定性
- 停止行为能够学习类型先验

目前不能声称

- 不是原文 Figure 3–5 的逐点复现
- 尚未复现 69K NYC 数据池
- RQ1 是公开数据上的缩减替代实验
- RQ2/RQ3 仍缺多随机种子统计检验
- 小网格实验不能替代 $|Q| = 20$ 的 MILP

后续计划与最终交付



- ① 接入 Gurobi/SCIP，在论文规模上求解原 MILP 与 IR-MILP；
- ② 运行 20–50 个随机种子，加入均值、标准差和显著性分析；
- ③ 对先验偏移、发现成本和 P 的估计误差做消融；
- ④ 整合成最终 PDF、实验代码、环境与一键复现说明。

总结

论文贡献

把数据增强、模型发现、最优停止和价格曲线统一到一个 AutoML 市场机制中。

我们的阶段贡献

- ① 实现并验证论文的停止 DP、经验定价与先验学习；
- ② 在公开数据上缩减复现 Data-Bandit RQ1；
- ③ 发现“自愿购买 vs. 强制选择”的建模缺口；
- ④ 给出 IR 外部选项与鲁棒定价修正；
- ⑤ 建立可复现、可测试、可版本化的代码与报告工程。

谢谢！欢迎提问

附录：可复现入口

- 一键运行: `make all`
- 单元测试: `make test`
- 原始结果: `results/summary.json`
- RQ1 结果: `results/rq1_summary.json`
- 表格结果: `results/tables/pricing_results.csv`
- 阶段报告: `report/main.pdf`
- 中期展示: `slides/midterm.pdf`
- 当前版本: `v0.3.0`

参考论文: Y. Han, S. Padmanabha, S. Wang, Z. Huang, J. Zhao, *Optimal Pricing for Data-Augmented AutoML Marketplaces*.