

数据增强 AutoML 市场：RQ1 与 RQ3

发现算法与先验学习的论文实验及缩减复现

课程大作业 C.3 · RQ1/RQ3 实验复现部分

数据要素市场课程 · 中期答辩

参考论文： *Optimal Pricing for Data-Augmented AutoML Marketplaces*

2026 年 7 月 18 日

你负责的两项 RQ 位于市场链条的两端



RQ1 回答什么？

组合空间太大时，Data-Bandit 能否用**更少模型训练**找到高质量的增强-模型组合？

RQ3 回答什么？

平台不知道买家类型比例时，能否仅凭**停止时间**学习真实先验？

统一讲述结构

每项都按“研究问题 → 对应算法 → 原论文实验 → 缩减复现 → 边界”展开。

RQ1: Data-Bandit 为什么能少训练？

[对应 Algorithm 2: Metam 风格增强搜索 + Exp3 模型选择]

每轮只做四步

- ① 增强层提出候选 T_i ;
- ② 按 Exp3 概率抽取一个模型 M_i ;
- ③ 只训练 $M_i \leftarrow (D_{\text{in}} \bowtie T_i)$, 得到奖励 r_i ;
- ④ 用重要性加权 $r_i/p_i(M_i)$ 更新模型权重.

一句话直觉

与其在一个增强上花 $|\mathcal{M}|$ 次训练测透, 不如先花 1 次快速筛选, 从而把预算用于更多增强.

四种方法

- **Data-Bandit**: 每轮抽一个模型
- **Data-All**: 每个增强训练全部模型
- **Data-Alt**: 固定低成本模型筛增强, 周期性完整搜模型
- **AutoML**: 只搜模型, 不加入外部数据

为什么用 Exp3 ?

增强不断改变输入数据, 模型奖励并非固定分布; Exp3 适合这种非平稳/对抗式反馈.

RQ1: 原论文在 1000 个任务上比较发现效率


[原文 §6, Figure 3]

原论文设置

- 69K 个 NYC Open Data 数据集
- 约 30M 列、3B 行
- 1000 个分类/回归任务
- Random Forest、XGBoost、Neural Network 等
- 横轴：搜索时间；纵轴：效用

原文结论

分类效用 > 0.85 ，次优略高于 0.7；
回归中固定任意时间点，Data-Bandit 也高于基线。



原文 Figure 3 图像部分；多数任务找到的增强数少于 10。

RQ1: 公开数据缩减复现怎样设计?

[UCI Wine Quality; 固定训练调用预算替代机器相关秒数]

数据与任务

- 红/白葡萄酒, 分类与回归各 30 个任务
- 2 个基础特征 + 9 个外部增强
- 6 个自包含模型族
- 每种方法最多 60 次模型训练
- 固定种子; 每任务 60/20/20 划分


避免“看起来能跑、实际泄漏”

- 训练集: 排序增强候选、拟合模型
- 验证集: 搜索与选择当前 incumbent
- 测试集: 只报告验证选择方案的效用

复现定位

NYC 数据池、Metam 配置和完整代码未公开;
这里复现预算语义和定性现象, 不逐点还原原图时间轴.

RQ1: Bandit 更早接近 oracle, 但终点不是最优



相对 Data-All

- AUC 配对差: 分类 +0.00794, 回归 +0.00335
- 95% bootstrap 区间均不跨 0
- 达到 95% oracle 增益所需训练减少 30.3% / 27.5%

必须同时说的边界

- 60 次预算终点仍是 Data-All 略高, 差距 0.0012–0.0015
- Bandit 与 Data-Alt 的 AUC 区间跨 0, 只能说表现相当

RQ3: 怎样从停止时间反推买家类型？

[对应 Algorithm 1; Algorithm 3 预计算各类型停止行为]

两阶段学习

- ① 对每类 θ_i 预计算停止似然

$$L_i(y) = \Pr(Y = y \mid \theta_i, x);$$

- ② 观察停止轮次 $y^{(t)}$ 后做 Bayes 更新

$$w_i^{(t)} = \frac{L_i(y^{(t)})\mu_i^{(t)}}{\sum_j L_j(y^{(t)})\mu_j^{(t)}};$$

- ③ 用学习率平滑

$$\mu^{(t+1)} = (1 - \eta_t)\mu^{(t)} + \eta_t \bar{w}^{(t)}.$$

实验要回答

- 学习是否收敛到真实先验 μ^* ?
- 学习率怎样影响速度和波动 ?
- 大批量能否平滑噪声 ?

必要前提：可识别性

不同类型必须产生可区分的停止分布；
否则只看停止轮次不可能区分它们。

RQ3: 原论文验证收敛、学习率与批量效应

[原文 §6, Figure 5 + Appendix D.2]

原论文设置

- $|Q| = 10$, 类型数 $n = 5$, $T = 15$
- 5 种先验: 随机、均匀、略偏、高偏、极偏
- 学习率: $1/(t+1)$ 、 $1/\sqrt{t}$ 、 $1/2$
- 批量: 10 与 100
- 指标: $D_{\text{KL}}(\mu^* \parallel \mu^{(t)})$

原文结论

KL 继续下降; 激进率更快但更不稳; 增大批量可平滑学习。




Figure 5: (a) $b = 100$, 1000 轮; (b) $b = 10$, 10000 轮; (c) $b = 100$, 10000 轮。

RQ3: 缩减复现显式构造“可区分类型”

[透明合成 Markov 环境，避免把可识别性藏在随机参数中]

停止似然怎样生成

- 10 个质量状态、最长 15 轮
- 转移：52% 停留、34% 升一级、14% 升两级
- 12000 条 Markov 轨迹
- 五类估值 + 发现成本 0.018
- 最优停止 DP 生成停止轮次频率


完整实验规模

- 平均停止轮次：1.0、4.0、7.2、10.2、12.6
- 最小成对 L_1 距离约 0.656
- 5 种先验 $\times$ 3 种学习率
- 批量 10/100、5 个种子、1000 轮
- 共 150 条学习运行

为什么要这样构造？

如果五类停止分布重合，学习失败可能只是不可识别，而不是 Algorithm 1 本身的问题。

RQ3: 激进率快但抖, 大批量更平滑



随机先验、批量 100

- 最终 KL ($1/(t+1)$, $1/\sqrt{t}$, $1/2$): 0.03752、0.00684、0.00519
- $1/2$ 最快, 但尾部波动 0.00353
- $1/\sqrt{t}$ 的尾部波动仅 0.00019

怎样下结论

- $1/(t+1)$: 最稳, 但过早变得保守
- $1/2$: 快, 但持续受批次噪声影响
- $1/\sqrt{t}$: 速度-稳定性折中
- 批量 10 + 常数率时明显失稳

RQ1 与 RQ3: 结论和可声称边界

RQ1: 发现效率

- Data-Bandit 以更少训练更早接近 oracle
- 相比 Data-All, AUC 差显著为正
- 但完整预算 Data-All 略高
- 相比 Data-Alt 只能说表现相当

RQ3: 先验学习

- Algorithm 1 能在可识别环境中收敛
- 激进学习率更快但更易振荡
- 大批量可平滑抽样噪声
- $1/\sqrt{t}$ 是较均衡的折中

统一的复现定位

RQ1 使用 UCI 替代 NYC 数据池; RQ3 使用合成 Markov 环境. 两者复现的是算法语义与定性结论, 不是 Figure 3/5 的逐点重现.

备查 A: Exp3 的概率与重要性加权

抽样概率

$$p_i(M) = (1 - \gamma) \frac{w_i(M)}{\sum_{M'} w_i(M')} + \frac{\gamma}{|\mathcal{M}|}.$$

奖励估计

只观察抽中模型 M_i :

$$\hat{r}_i(M_i) = \frac{r_i}{p_i(M_i)}.$$

小概率抽到却高奖励，获得更强修正。

权重更新

$$w_{i+1}(M_i) = w_i(M_i) \exp\left(\frac{\gamma \hat{r}_i(M_i)}{|\mathcal{M}|}\right).$$

其他模型权重本轮不变。

回答老师

除以抽样概率是为了校正不同模型被观察频率不同造成的偏差；均匀探索项防止某只臂永远失去机会。

备查 B: RQ1 的四个指标怎么读？

- ① **final utility**: 预算用尽时的测试效用，回答“最后谁最好”。
- ② **AUC**: $B^{-1} \sum_{b=1}^B U_b$ ，回答“谁更早找到好方案”。字段名中的 normalized 指除以预算长度，不是除以 oracle。
- ③ **达到 95% oracle 增益的训练数**:

$$\min\{b : U_b \geq U_0 + 0.95 \max(0, U^* - U_0)\}.$$

- ④ **配对 bootstrap**: 同一任务上先做方法差，再重采样任务；区间跨 0 就不能声称显著差异。

最容易说错

AUC 显著更高不等于最终性能显著更高；“更快接近最优”和“最终绝对最优”是两个问题。

备查 C: RQ3 关键数字与可识别性

学习率	最终 KL	尾部平均 KL	尾部标准差
$1/(t+1)$	0.03752 ± 0.01698	0.03765	0.00008
$1/\sqrt{t}$	0.00684 ± 0.00444	0.00695	0.00019
$1/2$	0.00519 ± 0.00166	0.00545	0.00353

批量 10 的警告

常数 $1/2$ 在五种先验上的平均最终 KL 约 0.1965, 尾部波动约 0.0488.

可识别性

若两类买家在所有可用价格下产生相同停止分布, 仅凭停止时间无法区分; 应引入更多信号或将其合并为有效类型.